



UNIVERSIDAD
DE GRANADA

TRABAJO FIN DE MÁSTER

MÁSTER UNIVERSITARIO EN CIENCIA DE DATOS E INGENIERÍA DE COMPUTADORES

LLMs para detección automática de lenguaje sexista en redes sociales

Autor

Miguel Ángel Benítez Alguacil

Directoras

María José Martín Bautista

Andrea Morales Garzón

Granada, septiembre de 2025

LLMs para detección automática de lenguaje sexista en redes sociales

Miguel Ángel Benítez Alguacil

Palabras clave: detección de sexismo, modelos grandes de lenguaje (LLMs), procesamiento del lenguaje natural (PLN), múltiples anotadores y desacuerdo

Resumen¹

Este trabajo aborda la detección automática de mensajes sexistas en foros y redes sociales mediante la aplicación combinada de *fine-tuning* y *prompting* sobre *Large Language Models* (LLMs). Los modelos de lenguaje resultan especialmente adecuados para esta tarea, ya que capturan matices semánticos y pragmáticos difíciles de codificar manualmente; sin embargo, su comportamiento varía significativamente según la arquitectura y el tamaño del preentrenamiento, lo que obliga a comparar alternativas en lugar de asumir un rendimiento homogéneo. Para evaluar la propuesta se emplean tres conjuntos de datos distintos, cubriendo así tanto lenguaje espontáneo como ejemplos diseñados para poner a prueba ambigüedades y matices.

La complejidad del problema se ve acentuada por su naturaleza subjetiva: los propios anotadores pueden discrepar sobre el carácter sexista de ciertos mensajes, lo que introduce ruido en las etiquetas y limita el techo de rendimiento alcanzable. El análisis de errores confirma que la ironía, las citas fuera de contexto y las frases con ambigüedad pragmática son focos habituales de discrepancia, sugiriendo líneas de trabajo futuras en detección de discurso figurado, modelado de incertidumbre y protocolos de adjudicación.

El flujo experimental se estructura en tres fases: (1) ajuste fino de arquitecturas BERT especializadas tras un rebalanceo de clases y un preprocesado de los datos; (2) comparación frente a LLMs generativos en esquemas de etiquetado binario y multicategoría; y (3) despliegue del modelo ganador como microservicio *REST* accesible desde una interfaz web. El diseño incluye una búsqueda sistemática de hiperparámetros, regularización mediante *early stopping* y la evaluación con *accuracy*, *precision*, *recall* y *F1 macro*, complementada con matrices de confusión.

Esta metodología se ha probado con distintas fuentes de datos y arquitecturas de modelos llegando a obtener una precisión alta en la clasificación de sexismo y un comportamiento consistente en los distintos conjuntos de prueba, lo que confirma que, pese a sus diferencias internas, los LLMs (ya sea mediante *fine-tuning* o *prompting*) son herramientas útiles y efectivas para detectar sexismo en textos. No obstante, los contrastes entre arquitecturas ponen de manifiesto que la transferencia de conocimiento no es uniforme: los encoders BERT especializados ofrecen mayor eficiencia y estabilidad cuando se dispone de datos anotados, mientras que los modelos generativos demuestran flexibilidad con menor esfuerzo de entrenamiento, resultando idóneos para escenarios con datos escasos o en constante evolución.

¹Aunque el español es un idioma muy rico en vocabulario, a lo largo del texto se emplean anglicismos (por ejemplo, *fine-tuning*, *prompting* o las siglas *LLM*) porque son la denominación predominante en la bibliografía especializada. Para facilitar la lectura, se incluye un glosario al final del documento con su equivalencia en español.

El proyecto sienta las bases para extender la taxonomía de etiquetas, incorporar corpus multilingües, mejorar la explicabilidad y la calibración de confianza a fin de reforzar la transparencia y la utilidad práctica en tareas de moderación de contenidos.

LLMs for automatic detection of sexism on social media

Benítez Alguacil, Miguel Ángel

Keywords: sexism detection, large language models (LLMs), natural language processing (NLP), multiple annotators, annotation disagreement

Abstract

This dissertation addresses the automatic detection of sexist messages in forums and social media through the combined application of fine-tuning and prompting on Large Language Models (LLMs). These models are particularly well-suited to this task, as they capture semantic and pragmatic nuances that are difficult to encode manually; however, their behaviour varies significantly depending on the architecture and size of the pre-training, so several alternatives must be compared rather than assuming homogeneous performance. Three different datasets are used to ensure thorough evaluation, covering both spontaneous language and examples designed to test ambiguities and nuances.

The complexity of the problem is accentuated by its subjective nature: annotators themselves may disagree on whether a given message is sexist, which introduces noise into the labels and limits the attainable performance ceiling. Error analysis confirms that irony, out-of-context quotes, and pragmatically ambiguous phrases are frequent sources of disagreement, suggesting future lines of work in figurative speech detection, uncertainty modelling, and adjudication protocols.

The experimental workflow is structured in three phases: (1) fine-tuning specialised BERT architectures after class rebalancing and data preprocessing; (2) comparing them with generative LLMs under both binary and multi-category labelling schemes; and (3) deploying of the best-performing model as a REST microservice accessible via a web interface. The design includes a systematic search for hyperparameters, regularisation through early stopping, and evaluation using accuracy, precision, recall, and macro-F1, complemented by confusion matrices.

This methodology has been tested with different data sources and model architectures, achieving high accuracy in sexism classification and consistent performance across the different test sets, confirming that, despite their internal differences, LLMs (whether through fine-tuning or prompting) are useful and effective tools for detecting sexism in texts. Nonetheless, the contrasts between architectures show that knowledge transfer is not uniform: specialised BERT encoders offer greater efficiency and stability when annotated data is available, whereas generative models demonstrate flexibility with less training effort, making them ideal for scenarios with scarce or constantly evolving data.

The project lays the groundwork for extending the label taxonomy, incorporating multilingual corpora, improving explainability and confidence calibration in order to enhance transparency and practical utility in content moderation tasks.

Yo, **Miguel Ángel Benítez Alguacil**, alumno de la titulación Máster Universitario en Ciencia de Datos e Ingeniería de Computadores de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI 75577060A, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Máster en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: Miguel Ángel Benítez Alguacil

Granada, a 4 de septiembre de 2025.

D. **María José Martín Bautista**, Catedrática del Área de Ciencias de la Computación e Inteligencia Artificial del Departamento de Ciencias de la Computación e Inteligencia Artificial de la Universidad de Granada.

D. **Andrea Morales Garzón**, Investigadora del Área de Ciencias de la Computación e Inteligencia Artificial del Departamento de Ciencias de la Computación e Inteligencia Artificial de la Universidad de Granada.

Informan:

Que el presente trabajo, titulado *LLMs para detección automática de lenguaje sexista en redes sociales*, ha sido realizado bajo su supervisión por **Miguel Ángel Benítez Alguacil**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada, a 4 de septiembre de 2025.

Las directoras:

María José Martín Bautista Andrea Morales Garzón

Agradecimientos

Quiero expresar mi más sincero agradecimiento a mi familia, por haberme acompañado en cada paso de este camino. A mis padres, por enseñarme desde pequeño el valor del esfuerzo, la constancia y la curiosidad, y por apoyarme incluso en los peores momentos. Gracias por creer en mí hasta cuando ni yo mismo lo hacía.

A mis amigos, por estar presentes incluso en la distancia, por aguantar mis peores días y por ofrecerme su apoyo cuando más lo necesitaba.

Por último, a mis tutoras, María José y Andrea, por su paciencia y dedicación durante este año, y por aconsejarme y ayudarme en todo lo necesario para llevar a cabo este proyecto.

Índice general

1. Introducción	1
1.1. Contexto	1
1.2. Justificación	2
1.3. Hipótesis	3
1.4. Objetivos	3
1.5. Cronograma	4
1.6. Organización	5
2. Fundamentación teórica	7
2.1. Avances en el campo del Procesamiento de Lenguaje Natural (PLN)	7
2.1.1. Evolución histórica	7
2.1.2. Preprocesamiento del texto	7
2.1.3. Arquitecturas Transformers	8
2.1.4. Situación actual	9
2.2. PLN y clasificación automática	10
2.2.1. Enfoques clásicos	10
2.2.2. Clasificadores basados en Transformers	10
2.2.3. Modelos generativos y <i>prompting</i>	12
2.3. PLN y Detección de Sexismo	13
2.3.1. Corpora y benchmarks relevantes	14
2.3.2. Retos de anotación y evaluación	16
3. Metodología	19
3.1. Flujo general de trabajo	19
3.2. Descripción del flujo de trabajo	20
3.3. Arquitectura del sistema	21
3.4. Conjuntos de datos	21
3.5. Procesos clave en la metodología	24
3.5.1. Preprocesamiento	24
3.5.2. Entrenamiento de modelos	25
3.5.3. Evaluación	27
4. Resultados y discusión	29
4.1. Pasos previos y configuración	29
4.2. Resultados principales	30
4.2.1. Clasificación binaria	31

4.2.2. Clasificación multiclase (cuatro etiquetas)	37
4.2.3. Clasificación multiclase: tres etiquetas	43
4.3. Comparativa BERT por intervalos de texto	48
4.4. Análisis cualitativo y casos de error	49
4.4.1. Estudio de la reducción del dataset de EDOS	49
4.4.2. Caso RedditBIAS. Sesgo vs. Sexismo	50
4.4.3. Análisis de casos en EDOS	53
4.5. Discusión	56
4.5.1. Lecciones extraídas de <i>EDOS</i>	57
4.5.2. Limitaciones del estudio	57
4.6. Conclusiones y trabajos futuros	57
5. Aplicaciones en sistemas reales	61
5.1. Arquitectura general	61
5.2. Caso de uso: aplicación de análisis de sexismo	61
5.2.1. Inicio de sesión	62
5.2.2. Página de inicio	62
5.2.3. Detector de sexismo	63
5.2.4. Analíticas	67
5.3. Persistencia de resultados	69
5.4. Gestión de usuarios y permisos	69
5.5. Flujo de navegación	71
5.6. Lecciones aprendidas y trabajo futuro	71
6. Conclusiones y trabajos futuros	73
6.1. Conclusiones principales	73
6.2. Trabajos futuros	73
6.2.1. Mejora del modelo y de la métrica	74
6.2.2. Arquitectura y eficiencia	74
6.2.3. Aplicaciones prácticas	74
6.2.4. Ampliación de datos y cobertura	74
Bibliografía	75
Apéndice A: Tablas completas de resultados	79
A.1. EDOS reduced dataset rows)	79
A.1.1. bert-base-uncased	79
A.1.2. ModernBERT-base	81
A.2. EDOS reduced dataset (10 k rows)	83
A.2.1. bert-base-uncased	83
A.2.2. ModernBERT-base	83
Apéndice B: Prompts empleados en los LLMs	85
B.1. Clasificación con 2 etiquetas	85
B.2. Clasificación con 3 etiquetas	86
B.3. Clasificación con 4 etiquetas	87
Glosario	91

Índice de figuras

1.1. Diagrama de Gantt del TFM	4
2.1. Transformer: Arquitectura del modelo. Vaswani et al. (2017)	8
2.2. Arquitectura y proceso de preentrenamiento/fine-tuning de BERT (adaptado de Devlin <i>et al.</i> , 2019).	11
2.3. VRAM necesaria para inferencia en bf16	14
3.1. Pipeline: Entrenamiento → Evaluación → Aplicación web.	20
3.2. Ejemplos de etiquetas y anotadores en EDOS. En verde, se representan aquellos casos en los que los anotadores indicaron “no sexista”, y en rojo los casos en los que se anotó “sexista”.	22
3.3. Ejemplos de etiquetas en RedditBIAS. Clasificación binaria: “biased” indica que el comentario tiene sesgo de género; “neutral” indica que no hay sesgo.	23
3.4. Ejemplos de etiquetas en Synthetic Phrases. Clasificación de tres clases (explicadas arriba)	24
4.1. “Snapshot” de la precisión de ModernBERT y otros modelos en una variedad de tareas, según lo medido por los estándares académicos de referencia.	30
4.2. Matriz de confusión para 2 etiquetas en EDOS (ModernBERT)	33
4.3. Resultados de F1 score por modelo y dataset	37
4.4. Matriz de confusión para 4 etiquetas en EDOS (ModernBERT)	38
4.5. Resultados de F1 score por modelo y dataset	42
4.6. Matriz de confusión para 3 etiquetas en EDOS (ModernBERT)	44
4.7. Resultados de F1 score por modelo y dataset	48
5.1. Pantalla de inicio de sesión	62
5.2. Panel principal <i>post-login</i>	62
5.3. Selector de modo de detección de sexismo.	63
5.4. Formulario para análisis de texto.	63
5.5. Resultados del análisis de texto.	64
5.6. Formulario de análisis de URL.	64
5.7. Resultados del análisis de una URL.	65
5.8. Formulario del analizador de dominio.	65
5.9. Resultado del análisis de un dominio.	66
5.10. Dashboard global de las analíticas.	67
5.11. Listado de dominios con URLs analizadas.	68
5.12. Listado paginado de URLs de un dominio.	68

5.13. Detalle del análisis de una URL concreta.	69
5.14. Panel de administración: Gestión de roles.	70
5.15. Panel de administración: Gestión de usuarios.	70
5.16. Perfil de usuario.	71

Índice de cuadros

2.1. Encoders derivados de BERT y memoria requerida para inferencia en FP16. Las variantes ModernBERT extienden la ventana de contexto y mejoran la relación rendimiento/parámetros.	12
2.2. LLMs evaluados y requisitos aproximados de GPU	12
3.1. Resumen de los corpora utilizados en el estudio.	24
3.2. Espacio de hiperparámetros considerado para la búsqueda en EDOS para clasificación binaria en el dataset reducido de 5 k comentarios.	26
4.1. Mejores hiperparámetros BERT en EDOS (reduced 5 k)	31
4.2. Resultados de clasificación binaria en EDOS (reduced 5 k)	31
4.3. Mejores hiperparámetros BERT en EDOS (reduced 10 k)	32
4.4. Resultados del <i>classification report</i> para 2 etiquetas en EDOS (ModernBERT)	33
4.5. Resultados de clasificación binaria en EDOS (reduced 10 k)	34
4.6. Resultados de clasificación binaria en RedditBIAS	35
4.7. Resultados de clasificación binaria en Synthetic Phrases (sin soft sexism)	36
4.8. Resultados de clasificación binaria en Synthetic Phrases (soft sexism = sexism)	36
4.9. Mejores hiperparámetros (BERT) para clasificación 4 etiquetas	38
4.10. Resultados del <i>classification report</i>	39
4.11. Resultados de clasificación 4 labels en EDOS	39
4.12. Resultados de clasificación 4 labels en RedditBIAS	40
4.13. Resultados de clasificación 4 labels en Synthetic Phrases	41
4.14. Mejores hiperparámetros (BERT) para clasificación de 3 etiquetas	43
4.15. Resultados del <i>classification report</i>	45
4.16. Resultados de clasificación 3 labels en EDOS	45
4.17. Resultados de clasificación 3 labels en RedditBIAS	46
4.18. Resultados de clasificación 3 labels en Synthetic Phrases	47
4.19. Comparativa de rendimiento por intervalos de longitud de frase en EDOS (test)	49
4.20. Resultados de clasificación binaria en EDOS (completo)	49
4.21. Resultados oficiales de Task A (sexist / not-sexist) en EDOS 2023	50
4.22. Ejemplos de frases con sus predicciones (RedditBIAS). En verde las que se mapean como unbiased y en rojo las biased.	52
4.23. Ejemplos de frases con sus predicciones (EDOS).	55
5.1. Flujo resumido de navegación según rol.	71

1.	Resultados de bert-base-uncased en el dataset EDOS (5k)	79
2.	Resultados de ModernBert-base en el dataset EDOS (5k)	81
3.	Resultados de bert-base-uncased en el dataset EDOS (10k)	83
4.	Resultados de ModernBERT en el dataset EDOS (10k)	83

Capítulo 1

Introducción

1.1. Contexto

La proliferación de contenidos generados por usuarios en redes sociales, foros y plataformas de noticias ha puesto de relieve la urgencia de identificar y mitigar expresiones de discurso sexista en línea. La automatización de esta tarea resulta crítica tanto para proteger a colectivos vulnerables como para facilitar estudios empíricos sobre la evolución de los sesgos de género.

El **sexismo** se define típicamente como cualquier forma de discriminación, prejuicio o estereotipo basados en el género, con especial incidencia en actitudes despectivas hacia las mujeres. En el entorno digital, el sexismo se manifiesta a través de comentarios, mensajes o contenidos en redes sociales, foros y otras plataformas en línea que refuerzan roles de género negativos o inferiorizan a un género frente a otro. Este fenómeno forma parte del espectro del discurso de odio en línea, centrándose específicamente en el género como objeto de ataque o burla. Por ejemplo, es común encontrar mensajes abiertamente hostiles como “Go back to the kitchen” (que implica que las mujeres solo deben estar en la cocina) o afirmaciones aparentemente “positivas” pero condescendientes como “Many women have a quality of purity that few men possess” (refuerza estereotipos de género tradicionales que idealizan a las mujeres como moralmente superiores, delicadas o espiritualmente más “puras”). Ambos casos constituyen expresiones sexistas: el primero corresponde al sexismo *hostil* (abiertamente denigrante) y el segundo al sexismo *benevolente* (un tono aparentemente positivo que en el fondo perpetúa estereotipos de inferioridad) [1]. Estos ejemplos ilustran cómo incluso frases en apariencia inocuas pueden llevar una carga sexista implícita.

En el presente Trabajo Fin de Máster (TFM), se aborda la problemática de la *detección de sexismo en textos mediante el uso de Large Language Models* (LLMs), y hasta qué punto dichos LLMs (en particular, arquitecturas discriminativas tipo *encoder* y modelos generativos *text-to-text*) son capaces de detectar sexismo con fiabilidad cuando se entrenan sobre corpora anotados como *EDOS (Explainable Detection of Online Sexism)*[2], que ofrece 20.000 comentarios en inglés etiquetados por triplicado. Una aportación añadida de este trabajo consiste en **estudiar de forma comparada el comportamiento de distintas arquitecturas** (tanto encoders como modelos generativos) para entender sus fortalezas y limitaciones relativas; esto resulta esencial, pues cada modelo ha sido pre-entrenado con objetivos y corpus diferentes y, en consecuencia, no todos reaccionan igual ante los matices semánticos y pragmáticos del discurso sexista.

La detección de expresiones misóginas es clave en numerosos escenarios, como la moderación de redes sociales o la generación de reportes de “hate speech”, dando lugar a aplicaciones prácticas que exigen tanto un marco teórico sólido como un sistema computacional escalable. No obstante, la naturaleza subjetiva del problema introduce un obstáculo adicional: **la discrepancia entre anotadores**. Incluso con guías detalladas, los etiquetadores pueden divergir en su interpretación de si un mensaje es sexista o no, especialmente en casos de ironía, sarcasmo o referencias culturales implícitas. Este desacuerdo genera ruido en los datos de entrenamiento y, a su vez, limita el techo de rendimiento alcanzable por los modelos.

Inicialmente se valoró explorar métodos de re-escritura inclusiva; sin embargo, ante la falta de conjuntos de datos debidamente anotados, esta línea de trabajo se dejó **fuera del alcance** del presente TFM. En consecuencia, el proyecto evolucionó hacia la detección de sesgos de género en corpora provenientes de diversas fuentes, con especial atención al sexismo en comentarios en inglés.

Así, se investigaron fuentes de datos comúnmente utilizadas para el entrenamiento de modelos para detección de sexismo, como *RedditBIAS*[3] y, sobre todo, *EDOS (Explainable Detection of Online Sexism)*[2], que proporciona un dataset ya anotado y permite una mayor reproducibilidad. El uso de LLMs y datasets cuidadosamente construidos permite avanzar en la automatización de este proceso, cuyas implicaciones a nivel social y tecnológico son más que notables.

En el capítulo 2 se profundiza en el marco teórico y el estado del arte que sustentan esta investigación.

1.2. Justificación

La relevancia de detectar el sexismo en el entorno digital radica en su prevalencia y en el daño que causa tanto a nivel individual como social. Estudios internacionales señalan que una proporción significativa de mujeres ha experimentado alguna forma de abuso o acoso en línea de carácter sexista. Por ejemplo, en una encuesta realizada en 2017 por “Pew Research Center” se reportó que 4 de cada 10 mujeres estadounidenses habían sido blanco de comentarios misóginos o sexualizados en redes sociales y hasta un 66 % había sido testigo de dichos comportamientos [4].

Este tipo de conductas no solo afecta el bienestar psicológico de las personas destinatarias (pudiendo provocar ansiedad o depresión), sino que además contribuye a silenciar voces femeninas en espacios públicos digitales, limitando su participación en debates y comunidades en línea. En términos más amplios, la normalización del discurso sexista en internet refuerza estereotipos dañinos y desigualdades de género existentes en la sociedad.

Por ello, contar con herramientas automáticas capaces de detectar y moderar contenido sexista tiene un alto impacto práctico: pueden auxiliar a plataformas y moderadores humanos a identificar comportamientos tóxicos a gran escala, promueven entornos en línea más seguros e inclusivos, y permiten recopilar datos para estudiar y comprender mejor la dinámica del sexismo en la comunicación moderna.

En síntesis, el sexismo en el entorno digital es un problema vigente y extendido, cuya mitigación es fundamental para garantizar la igualdad y el respeto en la esfera pública en línea.

Disponer de **sistemas automáticos de detección y señalización temprana** es clave para:

- **Moderación a escala:** asistir a equipos humanos en la identificación de discursos sexistas (explícitos o más sutiles) en grandes volúmenes de datos.
- **Creación de entornos seguros e inclusivos:** reducir la exposición de colectivos vulnerables y fomentar su participación en debates públicos.
- **Investigación social y lingüística:** recopilar corpora etiquetados que permitan estudiar la evolución de los sesgos y el impacto de políticas de plataforma.

Para entrenar este tipo de modelos se requieren conjuntos de entrenamiento amplios y cuidadosamente anotados. Lo ideal es tener datos anotados por múltiples anotadores para poder tener consenso y desacuerdo. Esta granularidad habilita tanto la clasificación binaria (*sexist* / *not sexist*) como el análisis fino de niveles de severidad, posibilitando soluciones más precisas y explicables, además de ser fácilmente extensible a otros ejes de discriminación (raza, orientación sexual, etc.) en futuros trabajos.

1.3. Hipótesis

Los *Large Language Models* (LLMs) se entrenan sobre billones de palabras procedentes de fuentes heterogéneas (libros, artículos, foros, Wikipedia, redes sociales, etc.). Como consecuencia, estos modelos adquieren *conocimientos lingüísticos de carácter muy general*, pero también patrones sobre la forma en que se expresan determinados fenómenos sociales (p. ej., el sexismo) en el lenguaje.

Este Trabajo Fin de Máster parte de la hipótesis de que **mediante el uso de LLMs, en concreto, arquitecturas basadas en representación tipo *encoder* y modelos generativos *text-to-text* podemos ser capaces de detectar sexismo con fiabilidad cuando se entrenan sobre corpora anotados.**

Estos supuestos se pondrán a prueba en el capítulo 4, donde se presentan los experimentos y resultados.

1.4. Objetivos

El objetivo general de este TFM consiste en diseñar e implementar un *sistema de detección de sexismo* que, fundamentado en *modelos de lenguaje*, sea capaz de clasificar el texto según su contenido sexista o no sexista. Con el fin de lograrlo de manera sólida, se han planteado los siguientes objetivos específicos:

- **O1:** Estudiar el estado del arte en detección de lenguaje sexista, conjunto de datos y modelos de lenguaje para este propósito.
- **O2:** Entrenar modelos de lenguaje que permitan detectar la presencia de contenido sexista en su contenido.
- **O3:** Evaluar el rendimiento de los modelos entrenados en datos etiquetados.

1.5. Cronograma

La presente sección detalla la planificación estratégica seguida para el desarrollo del Trabajo Fin de Máster, alineándose con los objetivos específicos planteados en la sección 1.4. A través de una planificación estructurada, se definen las distintas fases que han guiado la investigación, desde la revisión del estado del arte hasta la implementación de una aplicación práctica. Cada etapa responde a unos objetivos concretos que, en conjunto, permiten abordar de forma integral el problema de la detección automática de sexismo en texto. La figura 1.1 resume visualmente este itinerario, que se desgrena a continuación paso a paso.




Figura 1.1: Diagrama de Gantt del TFM

- Revisión bibliográfica y fundamentación:** Recopilar los principales trabajos relacionados con la detección de sesgos y discurso de odio en textos, así como con el uso de modelos de lenguaje de última generación.
- Selección y análisis de datasets:** Identificar, filtrar y procesar uno o varios conjuntos de datos con anotaciones de sexismo o discurso misógino. Adaptar dichos datos a la estructura y requisitos de los modelos empleados.
- Entrenamiento y experimentación con LLMs:** Utilizar modelos tipo BERT (o variantes modernas) para entrenar un clasificador capaz de identificar contenido sexista. Ajustar hiperparámetros y, en caso necesario, explorar técnicas adicionales de mejora.
- Evaluación de resultados y análisis cualitativo:** Verificar la eficacia del sistema a través de métricas estándar (*precision*, *accuracy*, F1, etc.) y de un análisis cualitativo. Discutir los errores más frecuentes y la fiabilidad global.
- Validación externa del modelo:** Evaluar el rendimiento en corpora no vistos (p. ej., *RedditBIAS* y un mini-corpus sintético) y comparar los resultados con los obtenidos en *EDOS*.
- Desarrollo de una API o prototipo funcional:** Diseñar un sistema (mediante *FastAPI*, framework de Python) que reciba textos y devuelva la probabilidad de que contengan expresiones sexistas, fomentando la escalabilidad y la usabilidad de la solución.

7. **Proyección de trabajos futuros:** Proponer líneas de investigación orientadas a mejorar la robustez y explicabilidad del sistema, considerando posibles extensiones del enfoque a otros tipos de sesgos.

Enfoque de desarrollo En este proyecto se ha optado por un enfoque de desarrollo ágil inspirado en la filosofía de *Scrum*, que promueve la entrega gradual de resultados y la revisión continua de los objetivos. Se han llevado a cabo **reuniones semanales con las tutoras** donde se discutían los avances logrados, se revisaban las necesidades emergentes del proyecto y se asignaban las prioridades de cada tarea.

Este proceso ha permitido una comunicación fluida durante la semana y una *retroalimentación* frecuente, ajustando la ruta de desarrollo a medida que se descubrían retos o aparecían nuevas ideas.

1.6. Organización

El documento se estructura de la siguiente forma:

1. **Introducción (capítulo actual):** Presenta el contexto, la justificación y la hipótesis, junto con los objetivos y la organización de este TFM.
2. **El capítulo 2 presenta la fundamentación,** donde se expone el marco teórico y el estado del arte en torno a los modelos de lenguaje, especialmente en el ámbito de detección de sexismo.
3. **El capítulo 3 describe la metodología,** detallando la estrategia seguida para recolectar, limpiar y anotar los datos, así como el *pipeline* de entrenamiento y validación de los modelos.
4. **El capítulo 4 recoge los resultados y la discusión,** mostrando las métricas obtenidas y un análisis crítico de los hallazgos, incluidos ejemplos de errores y aciertos relevantes.
5. **El capítulo 5 explora las aplicaciones en sistemas reales,** mediante el diseño de un prototipo funcional que analiza textos, URLs y dominios completos empleando el clasificador ModernBERT.
6. **El capítulo 6 expone las conclusiones y trabajos futuros,** sintetizando las principales aportaciones e identificando posibles extensiones y mejoras para investigaciones posteriores.

Con todo ello, se espera proporcionar una visión completa de la detección de sexismo a través de modelos de lenguaje, abarcando tanto los fundamentos teóricos como las aplicaciones prácticas y reflexiones finales. El siguiente capítulo profundiza en el marco teórico y el estado del arte que sustenta los objetivos aquí planteados.

Capítulo 2

Fundamentación teórica

2.1. Avances en el campo del Procesamiento de Lenguaje Natural (PLN)

2.1.1. Evolución histórica

Durante las dos últimas décadas, el *Procesamiento de Lenguaje Natural* (PLN) ha pasado de emplear representaciones basadas en vocabularios fijos (que modelaban cada término como una dimensión independiente) a utilizar modelos profundamente contextuales con miles de millones de parámetros. Este recorrido puede resumirse en tres grandes fases:

1. **Representaciones léxicas estáticas.** Métodos como *bag-of-words*, TF-IDF o *n-grams* caracterizaban un documento mediante la simple presencia o frecuencia de términos. Aunque eficaces para tareas de clasificación tempranas, ignoraban la polisemia y la relación semántica entre palabras.
2. **Word embeddings densos.** Con *word2vec* y *GloVe* se introdujo la idea de aprender vectores densos a partir de grandes corpus [5]. Estas técnicas capturaban similitudes léxicas, pero asignaban el mismo vector a una palabra independientemente de su contexto.
3. **Transformers y la era de los LLM.** El Transformer (2017) introduce la auto-atención (los aspectos técnicos ya se definieron en subsección 2.1.3); BERT (2018-19) populariza MLM para modelos de representación; los modelos generativos como GPTs y sucesores escalan a cientos de miles de millones de parámetros, inaugurando la inteligencia artificial (IA) generativa.

2.1.2. Preprocesamiento del texto

Antes de la fase de modelado, todo sistema de PLN ejecuta un **pipeline de preprocesado** que convierte el texto *raw* en una secuencia de identificadores numéricos. Primero se aplica una normalización ligera (por ejemplo, conversión a minúsculas, eliminación de emojis o URLs y corrección de espacios múltiples) para homogenizar la entrada.

A continuación, un *tokenizador* segmenta la cadena en unidades manejables (palabras, sub-palabras o símbolos) siguiendo reglas dependientes del modelo: los métodos clásicos trabajan con *tokens* de palabra, mientras que los LLMs actuales emplean sub-palabras aprendidas automáticamente mediante algoritmos como *Byte-Pair Encoding (BPE)* o *WordPiece*[6]. Cada token se asigna después a un índice de un vocabulario fijo, produciendo un vector de enteros que se alimenta al modelo junto con posiciones y, en su caso, máscaras de atención. Este paso de “texto $\rightarrow$ tokens $\rightarrow$ IDs” es crucial, pues determina la granularidad semántica y la eficiencia con que redes posteriores, desde las basadas en *bag-of-words* hasta los Transformers, pueden capturar dependencias léxicas y contextuales.

A lo largo de este capítulo, se detallan los conceptos más relevantes para el desarrollo de este proyecto. Antes de profundizar en los distintos paradigmas y familias de modelos, conviene definir brevemente los conceptos esenciales que se emplearán a lo largo de este capítulo.

2.1.3. Arquitecturas Transformers

Un *Transformer* es una arquitectura de red neuronal introducida por Vaswani et al. (2017) [7] que sustituye la recurrencia por un mecanismo de **auto-atención**, capaz de asignar pesos de relevancia entre todos los pares de tokens de la secuencia de entrada en paralelo. Ello permite capturar dependencias largas con mayor eficiencia computacional y ha desplazado a las RNN y CNN en la mayoría de tareas de PLN.




Figura 2.1: Transformer: Arquitectura del modelo. Vaswani et al. (2017)

El rol de la atención en los modelos de lenguaje El bloque de atención (Figura 2.1) calcula pesos de relevancia (*scores*) entre pares de tokens, permitiendo que el modelo se centre en las partes más informativas de la oración. Este mecanismo, junto con el paralelismo inherente al Transformer, ha posibilitado el entrenamiento de modelos cada vez más grandes.

Large Language Model (LLM). Un LLM es un modelo de lenguaje con cientos o miles de millones de parámetros, pre-entrenado con autoregresión o enmascarado sobre corpus masivos de texto (billones de tokens). Gracias a su escala, los LLM son capaces de *comprender* y *generar* lenguaje natural de forma versátil, abordando desde la traducción hasta la redacción creativa [8]. Se distinguen dos grandes familias: (i) *encoders* para *representación* (p.ej. BERT) y (ii) *decoders* autoregresivos para *generación* (p.ej. GPT, Llama, Mistral).

Modelo de representación vs. generativo. Los modelos de *representación* producen vectores densos que sintetizan el significado contextual de un texto; son idóneos para clasificación, recuperación semántica y detección de sesgo. Los modelos *generativos* predicen la siguiente palabra dada la historia previa y destacan en tareas de redacción y diálogo. Ambos comparten la base Transformer, pero optimizan objetivos distintos (*Masked Language Modeling (MLM)* frente a *Next-Token Prediction*).

- **MLM:** objetivo de preentrenamiento (popularizado por BERT) donde se toma una frase y se oculta un porcentaje de los tokens con un marcador especial “[MASK]”. El modelo debe predecir cada token oculto usando todo el contexto a izquierda y derecha. El encoder aprende representaciones bidireccionales (entiende simultáneamente el pasado y el futuro del token) y capta dependencias de largo alcance sin necesidad de generar palabras en orden. En la figura 2.2 podemos observar la arquitectura de BERT junto con las “masked sentences” en el preentrenamiento.
- **Next-Token Prediction:** al contrario que MLM, el modelo sólo ve el contexto a la izquierda y aprende a predecir el siguiente token de la secuencia (ampliamente usado por GPT, Llama, etc.).

Impacto en aplicaciones. Modelos de representación como BERT sobresalen en clasificación, búsqueda semántica o *question answering* porque producen vectores fijos que codifican el contexto. Por su parte, los generativos son clave en tareas de redacción asistida, resumen y, como se verá en la Sección 2.2.3, funcionan como detectores *few-shot* mediante *prompting*.

2.1.4. Situación actual

Modelos como ModernBERT extienden la ventana a 8k tokens mediante posiciones rotatorias (RoPE) y capas GeGLU, mientras que LLMs de 7B–70B parámetros (GPT-4, Llama 3) dominan la IA generativa, habilitando *prompting* y *few-shot learning*. Las Secciones 2.2.3 y 2.2 profundizan en su rendimiento y coste.

2.2. PLN y clasificación automática

La tarea de detección automática de sexismo ha seguido, en gran medida, la evolución general de las técnicas en procesamiento de lenguaje natural para clasificación de texto, desde enfoques de *machine learning* basados en rasgos superficiales, pasando por la adopción de modelos neuronales (particularmente Transformers), hasta las aproximaciones más recientes que involucran modelos de lenguaje de gran tamaño (LLMs) con *prompting*. En esta sección se describen dichas etapas, destacando sus características, coste computacional de cada familia, avances y se justifica la selección de modelos probados en este TFM.

2.2.1. Enfoques clásicos

Los primeros trabajos (2015–2018) emplearon **algoritmos lineales** (principalmente SVM y regresión logística) entrenados sobre representaciones *bag-of-words* o *n-grams* de palabras/caracteres [9]. Su fuerza residía en la facilidad de interpretación (coeficientes asignados a cada término) y el bajo coste de inferencia: un vector disperso de unos pocos miles de dimensiones cabe en memoria CPU y predice en milisegundos.

A medida que crecían los corpora aparecieron las **redes neuronales superficiales**. Convolucionales (*CNN*) y LSTM equipadas con *word-embeddings* (GloVe o word2vec) superaron a las SVM en datasets como AMI 2018 [10] o HateTweets17 [11]. No obstante, su contexto limitado (ventana de 3–5 palabras) y la dependencia de mucha anotación hacían que fallaran en ironía, sarcasmo o sexismo benevolente.

Principales limitaciones.

- **Dependencia léxica:** cambios mínimos (sinónimos, errores ortográficos) burlan al clasificador.
- **Contexto corto:** la CNN no ve la oración completa; la LSTM degenera en textos largos.
- **Escasa explicabilidad fina:** salvo análisis de pesos, no aclara “por qué” decide que un texto es sexista.

Estas limitaciones motivaron el salto a modelos pre-entrenados con atención contextual.

2.2.2. Clasificadores basados en Transformers

La irrupción de BERT [12] marcó un punto de inflexión: un *encoder* Transformer, pre-entrenado en tareas de lenguaje generales, puede ajustarse con apenas 5–10 épocas a un corpus especializado y superar ampliamente a las CNN/LSTM. La Tabla 2.1 resume los modelos evaluados en este trabajo y su coste estimado en VRAM usando precisión FP16¹:

La Figura 2.2 presenta, en un único vistazo, el recorrido completo de BERT desde el **preentrenamiento** hasta el **ajuste fino**. En el panel de la izquierda se observan las dos tareas auto-supervisadas que integran el pre-training original: (i) *Masked Language Modeling* (flechas rojas hacia los tokens enmascarados), donde el modelo intenta reconstruir

¹Coste en memoria para inferencia calculado de acuerdo al artículo de NVIDIA (#B Params x 2 bytes de FP16 x 2)

un 15 % de palabras ocultas, y (ii) *Next Sentence Prediction* (NSP), que decide si la oración B sigue realmente a la oración A en el corpus; ambas obligan a las capas de *multi-head self-attention* del bloque interno a aprender representaciones bidireccionales sólidas.

El panel derecho ilustra la fase de *fine-tuning*: se reutiliza el mismo encoder pre-entrenado (zona azul) y se añade una *capa de salida mínima y específica* para cada tarea downstream (clasificación MNLI, secuenciación NER, respuesta a preguntas SQuAD), de modo que con sólo unas pocas épocas el modelo alcanza el estado del arte sin modificar la arquitectura interna.

Los conectores punteados recuerdan que los pesos aprendidos durante el pre-training sirven como punto de partida común; durante el ajuste fino *todas* las capas se actualizan (flechas grises), lo que explica la rápida convergencia en dominios especializados.

En suma, la figura ilustra la filosofía “pre-train once, fine-tune everywhere” que convirtió a BERT y sus derivados en la referencia obligada para tareas como la detección de sexismo descrita en esta sección.




Figura 2.2: Arquitectura y proceso de preentrenamiento/fine-tuning de BERT (adaptado de Devlin *et al.*, 2019).

¿Por qué ModernBERT? En el artículo de Warner *et al.* (2024)[13] proponen una “actualización integral” de la familia BERT que incorpora optimizaciones surgidas en los últimos cinco años (RoPE, GeGLU, atención alterna y un preentrenamiento mucho más extenso (≈ 2 T tokens)).

Para contextualizar su aportación, la tabla 2.1 compara los encoders BERT más usados (desde *DistilBERT*, orientado a móviles, hasta las nuevas variantes *ModernBERT*) según tamaño, ventana de contexto y memoria de inferencia. Obsérvese que, aun añadiendo un 30 % más de parámetros, *ModernBERT-base* multiplica por 16 la longitud de entrada (8192 tokens) gracias a las **rotary position embeddings** (RoPE) y mejora la eficiencia de la MLP interna al sustituir ReLU/GELU por **GeGLU**, todo ello manteniéndose por debajo de 1 GB FP16.

Esta combinación hace que ModernBERT supere a BERT-base en tareas de clasificación y recuperación sin exigir el hardware de un LLM completo.

Además de la ampliación de contexto, ModernBERT introduce:

- **RoPE** (posicional rotatorio) $\Rightarrow$ extrapola a textos largos.

Modelo	# Parámetros	Contexto máx.	VRAM @ fp16≈
DistilBERT	66 M	512	≈ 0.26 GB
BERT _{base}	110 M	512	0.44 GB
BERT _{large}	340 M	512	1.36 GB
RoBERTa _{base}	110 M	512	0.44 GB
RoBERTa _{large}	355 M	512	1.4 GB
ModernBERT _{base}	149 M	8192 (RoPE)	0.6 GB
ModernBERT _{large}	395 M	8192 (RoPE)	1.6 GB

Tabla 2.1: Encoders derivados de BERT y memoria requerida para inferencia en FP16. Las variantes ModernBERT extienden la ventana de contexto y mejoran la relación rendimiento/parámetros.

- **GeGLU** en la capa feed-forward $\Rightarrow$ mejor relación calidad/parámetros.
- **Pre-entrenamiento masivo** (1.7 T tokens) $\Rightarrow$ mayor cobertura léxica moderna.

Ventajas operativas.

1. **Fine-tuning rápido:** $\approx$ 8 min/época en una RTX 3090 (24 GB) con lotes de 32.
2. **Inferencia *batch*:** 5 000 frases/seg en GPU o 1500 frases/seg en CPU avx2.
3. **Explainability básica:** atención + *Layer Integrated Gradients* permiten destacar tokens clave.

2.2.3. Modelos generativos y *prompting*

Los LLMs autoregresivos (GPT-3/4, Llama 2/3, Mistral, Gemma, etc.) añaden flexibilidad: basta un *prompt* bien diseñado para convertirlos en clasificadores *zero/few-shot*, sin entrenar pesos. La Tabla 2.2 compara los modelos generativos ensayados.

Modelo	# Parámetros	Ventana	VRAM @ fp16
Gemma-2-2B [14]	2 B	8 k	~ 8 GB
Llama-3.2-1B [15]	1 B	8 k	~ 4 GB
Llama-2-7B [16]	7 B	4 k	~ 28 GB
Mistral-7B-Instruct v0.3 [17]	7 B	32 k	~ 28 GB

Tabla 2.2: LLMs evaluados y requisitos aproximados de GPU

Hemos elegido modelos de distintos tamaños y familias para poder hacer una comparación de cómo se comportan como clasificadores en base al tamaño del número de parámetros

Estrategias de *prompting*.

1. **Zero-shot:** se describe la tarea y se pide “0 / 1”.

2. **Few-shot:** mejora el prompt de *zero-shot* añadiendo ejemplos y el resultado esperado.
3. **Logits masking + temperature=0:** restringe la salida a $\{0,1,2,3\}$ y evita alucinaciones.

Es importante señalar que, si bien prometedores, los modelos generativos y el prompting conllevan **sus propios retos**. En particular, los LLMs pueden exhibir sesgos o alucinaciones: por ejemplo, si el *prompt* no está bien calibrado, un modelo podría sobregeneralizar y marcar como sexista un texto neutro que simplemente menciona “mujeres” [18]. Esto se relaciona con el hecho de que los LLMs, al ser entrenados en datos de internet, también han absorbido estereotipos.

Justificación de uso. Para este trabajo se ha decidido utilizar los modelos *Gemma-2-2B*, *Llama-3.2-1B*, *Llama-2-7B* (con un finetuning en textos sexistas) y *Mistral-7B-Instruct v0.3* por las siguientes razones:

- **Barreras de hardware mínimas.** Modelos como *Gemma-2-2B* y *Llama-3.2-1B* caben íntegramente en ≤ 8 GB de VRAM cuando se cargan en FP16 [19]. Esto permite ejecutar y afinar ambos modelos en GPUs de gama media (RTX 3050/3060) o incluso en CPU con suficiente RAM, sin técnicas de cuantización ni adaptadores externos.
- **Comparativa coste – rendimiento.** Un encoder discriminativo como *ModernBERT-base* procesa del orden de 148 k tokens/s en una RTX 4090 gracias a Flash-Attention 3 [13]. Los generativos de 7 B rondan las 52-194 tokens/s en la misma GPU [20], ofreciendo un buen compromiso para experimentos de *zero/few-shot* sin re-entrenar pesos.
- **Ventana de contexto extendida.** *Mistral-7B-Instruct v0.3* soporta 32 k tokens sin ventana deslizante [21], útil para documentos completos. *Gemma-2-2B* y *Llama-3.2-1B* mantienen 8k, suficiente para los hilos de X (anteriormente Twitter) y textos un poco más largos analizados en nuestro corpus.
- **Escalabilidad de memoria.** Ejecutar *Llama-2-7B* en FP16 exige ~ 28 GB de VRAM, justificando su uso solo en la fase de ablation en A100, mientras que los modelos de ≤ 2 B parámetros permiten replicar los experimentos en un ordenador portátil o cloud gratuito.

Gráfica comparativa tamaño-VRAM

La Figura 2.3 visualiza el compromiso: modelos de hasta 110M caben en GPU de consumo (~ 8 GB), mientras que LLMs de 7 B exigen tarjetas de gama alta (28 GB) o cuantización agresiva.

2.3. PLN y Detección de Sexismo

La detección de sexismo es una aplicación crítica del PLN que ha evolucionado en paralelo a los avances arquitectónicos. Los primeros enfoques basados en léxicos y clasificadores




Figura 2.3: VRAM necesaria para inferencia en bf16.

lineales lograban identificar insultos explícitos pero fallaban ante lenguaje sutil. La adopción de BERT permitió considerar el contexto completo y mejoró drásticamente la F1 en corpora como AMI-2018 [10] y EXIST-2021[22] (se detallarán en la sección siguiente).

Retos particulares. A diferencia de otras tareas de toxicidad, el sexismo puede presentarse en formas benevolentes o irónicas, exigiendo modelos capaces de captar pragmática y discurso implícito. Además, la clase positiva es minoritaria ($<5\%$) en dominios abiertos, lo que obliga a técnicas de re-balanceo y métricas robustas ($F1$ macro, AUPRC).

Tendencias actuales. La comunidad explora LLMs para *zero/few-shot* en detección de sesgo, taxonomías más finas (EDOS 2023) y métodos de explicabilidad que destaquen las palabras responsables de la clasificación. Igualmente, se trabaja en la mitigación de sesgos del propio modelo y en la evaluación multilingüe.

2.3.1. Corpora y benchmarks relevantes

A lo largo de la última década se han desarrollado numerosos *corpora* y conjuntos de datos de referencia (*benchmarks*) para el entrenamiento y evaluación de sistemas de detección automática de contenido sexista. Estos datasets proveen ejemplos reales (y en algunos casos sintéticos) de lenguaje sexista y no sexista, sirviendo como base para investigar métodos de clasificación.

A continuación, se describen los recursos más destacados y utilizados en la literatura, incluyendo *benchmarks* recientes enfocados explícitamente en sexismo.

Primeros corpus en redes sociales. Uno de los primeros **corpora de sexismo** ampliamente utilizados proviene del trabajo de Waseem y Hovy (2016)[9], quienes recopilaron tuits en inglés anotados en tres categorías: sexista, racista o ninguno. Este dataset, con miles de tuits obtenidos de Twitter (ahora, X), fue pionero en la detección de lenguaje abusivo dirigido a mujeres (misoginia) y a minorías étnicas. En él se incluyeron ejemplos

explícitos de insultos y descalificaciones basadas en género; por ejemplo, tuits llamando a mujeres con términos denigrantes. A partir de este trabajo inicial, otros investigadores extendieron la labor de recolección de datos, prestando atención a distintas facetas del sexismo.

Competiciones pioneras: AMI (2018) En el ámbito de las competiciones y retos compartidos, cabe mencionar la serie de tareas denominadas AMI (Automatic Misogyny Identification) introducidas en 2018 [10]. El primer reto AMI (IberEval 2018) proporcionó datos en español e inglés de Twitter, anotados con etiquetas binaria de misoginia (misógino vs. no misógino) y categorías más finas de misoginia (por ejemplo, violencia, estereotipos, objetivación, etc.). Este evento marcó uno de los primeros *benchmarks* enfocados exclusivamente en la identificación de misoginia en redes sociales, evidenciando el interés creciente de la comunidad por abordar este problema de forma multilingüe.

Taxonomías bilingües: EXIST. En 2021 se lanzó el desafío **EXIST (sEXism Identification in Social neTworks)** en IberLEF 2021 [22]. El corpus de EXIST es particularmente notable por su carácter bilingüe (inglés y español) y multi-plataforma, recopilando unos 11.000 textos anotados procedentes de dos redes sociales (Twitter (ahora, X) y Gab) en su primera edición y más de 12,000 en la edición de 2022 [23]. Cada publicación está anotada en dos niveles: (1) identificación binaria de sexismo (sexista o no) y (2) categorización de tipo de sexismo, utilizando una taxonomía que abarca casos de contenido ideológico (e.g., ideas de inferioridad de la mujer), estereotipos y dominación, objetivización sexual, misoginia directa o violencia (física o no física), entre otros. Un aspecto destacable de EXIST es que incorporó contribuciones tanto de anotadores externos (vía crowdsourcing) como de expertos entrenados, reconociendo la importancia de la calidad en la anotación para este tipo de tarea sensible [23]. Los *benchmarks* de EXIST han estimulado la creación de sistemas multilingües y han resaltado la necesidad de enfoques robustos dada la limitada cantidad de ejemplos en idiomas distintos del inglés.

Evaluación de sesgo conversacional: RedditBIAS. Además de los corpora centrados específicamente en sexismo, existen **datasets de sesgos de género** más generales que, si bien no categorizan explícitamente en “sexista/no sexista”, resultan pertinentes para evaluar modelos de lenguaje. Un ejemplo importante es **RedditBIAS** [3], un recurso presentado por Barikeri et al. (2021) con el objetivo de medir y mitigar sesgos en modelos conversacionales. RedditBIAS consiste en más de 20.000 intervenciones tomadas de conversaciones reales en Reddit, abarcando cuatro dimensiones de sesgo: género, raza, religión y orientación sexual. Dentro de la dimensión de género, este subdataset de 3.000 comentarios permite evaluar si los modelos muestran sesgos de género o no. Por ejemplo, contiene pares de diálogo donde solo cambia el género de la persona mencionada, para probar si el modelo responde de forma sesgada. Aunque RedditBIAS no es un corpus de “clasificación de sexismo” per se, es muy útil como *benchmark* para examinar cómo los modelos (especialmente los LLMs conversacionales) manejan contenido potencialmente sesgado o estereotípico.

Taxonomía jerárquica y explicabilidad: EDOS. Más recientemente, la comunidad internacional de PLN ha contado con **EDOS (Explainable Detection of Online Sexism)**, introducido como el Task 10 de SemEval-2023 [2]. EDOS representa un avance

significativo al proponer no solo un nuevo conjunto de datos de gran tamaño, sino también un esquema jerárquico de etiquetado diseñado para fomentar la explicabilidad en la detección de sexismo en línea. El dataset de EDOS contiene aproximadamente 20,000 comentarios en inglés obtenidos de plataformas como Reddit y Gab, cada uno de los cuales ha sido cuidadosamente anotado por tres anotadores distintos bajo una taxonomía de sexismo de varios niveles. En concreto, el desafío se estructuró en tres subtarear jerárquicas: (A) detección binaria de sexismo (determinar si un mensaje es sexista o no), (B) categorización de alto nivel del tipo de sexismo (por ejemplo, si es un caso de insulto directo, de estereotipo de género, de dominación, de lenguaje condescendiente, etc.), y (C) clasificación fina en subcategorías más granulares del contenido sexista (con un total de 23 subclases específicas de sexismo definidas en la taxonomía). Por ejemplo, dentro de la taxonomía de EDOS se distinguen categorías como “Ideological sexism” (sexo débil, inferioridad intelectual o moral de un género), “Stereotyping & Dominance” (p.ej., afirmaciones que refuerzan roles tradicionales o supeditación de la mujer), “Objectification” (comentarios que tratan a la mujer como objeto sexual), “Threats of Violence” (amenazas explícitas de daño físico o sexual por razón de género), entre otras muchas. Cada comentario del corpus viene anotado con este tipo de etiquetas explicativas, lo cual no solo permite entrenar modelos para detectar sexismo, sino también obtener información de por qué un determinado texto es considerado sexista (en función de la categoría asignada). Este enfoque jerárquico y explicativo responde a la crítica de que una simple clasificación binaria carece de contexto y no ayuda a entender la naturaleza del sesgo. Gracias a EDOS, se cuenta ahora con un *benchmark* unificado y de amplia cobertura para comparar distintos sistemas, que a su vez ha impulsado el desarrollo de métodos más interpretables en la detección de contenido sexista.

Iniciativas recientes y multilingües: BeyondGender. La rápida evolución del campo ha motivado la creación de **datasets multifacéticos y multilingües**. BeyondGender (Luo et al., 2025) [24] es un corpus bilingüe (inglés-chino) con alrededor de 6,000 instancias de sexismo en inglés, 1.700 en chino y 13.000 ejemplos neutros. Introduce un esquema rico de anotación: aspecto (estereotipo, insulto, cosificación), género objetivo (misoginia vs. misandria) y tono (*hostil* vs. *benevolente*). Los autores muestran que incluso los LLMs actuales logran F1 elevados en misoginia inglesa pero tropiezan con formas sutiles y con la misandria en chino, subrayando la necesidad de seguir ampliando y refinando los datos.

En resumen, el campo cuenta ya con una variedad importante de corpora (aunque escasa comparada con otros campos): desde los pioneros basados en redes sociales (Twitter, ahora X) hasta recientes *benchmarks* con taxonomías jerarquizadas y datos sintéticos. Estos recursos han sentado las bases para el desarrollo y comparación de técnicas automáticas, proporcionando tanto ejemplos de “*lo que es sexista*” como de “*cómo se manifiesta el sexismo*” en diversas formas. A continuación, revisaremos cómo han evolucionado las estrategias y modelos para detectar automáticamente el sexismo aprovechando estos datos.

2.3.2. Retos de anotación y evaluación

La precisión de cualquier detector automático depende críticamente de la calidad de los datos anotados. Dos retos sobresalen en el caso del sexismo:

Subjetividad y contexto sociocultural. La percepción de qué enunciados resultan ofensivos varía según edad, dialecto, ideología o incluso la familiaridad con jerga propia de foros específicos. No es raro encontrar coeficientes κ inter-anotador inferiores a 0.6 en corpora multiclase [25]. Las buenas prácticas actuales incluyen (i) guías de anotación iterativas y pilotos de calibración, (ii) *crowdsourcing* estratificado para garantizar diversidad demográfica y (iii) recolección del razonamiento del anotador para posteriores tareas de explicabilidad.

Desequilibrio y rareza de los fenómenos. En redes generalistas el sexismo explícito es minoritario (1 – 5 % de los mensajes) [26]. Un corpus sin reequilibrar induce clasificadores que maximizan *accuracy* ignorando la clase minoritaria. Las estrategias habituales son el *undersampling/oversampling* y la ponderación de pérdida (*class-weighted loss*) durante el entrenamiento, pero ambos métodos pueden introducir sesgos si se aplican sin un análisis previo de representatividad.

Métricas adecuadas. La literatura desaconseja el uso exclusivo de *accuracy* y aboga por F_1 *macro* o AUPRC, que son insensibles al reparto de clases, así como por reportar resultados separados para sexismo explícito e implícito [26]. Además, varios trabajos recientes proponen métricas que penalizan la sobre-censura de discurso legítimo (*false-alarm penalty*) con objeto de alinear la evaluación con los principios de la libertad de expresión [27].

En resumen, en este capítulo hemos delimitado el *qué* y el *por qué* de la detección automática de sexismo: (i) su definición e impacto social en entornos digitales, (ii) los corpora y *benchmarks* que constituyen la materia prima de la tarea, (iii) los principales retos de anotación y evaluación, y (iv) la evolución de las técnicas, desde enfoques supervisados clásicos hasta modelos generativos con *prompting*. Estos cuatro pilares proporcionan el marco conceptual necesario para comprender las decisiones experimentales que vertebran esta investigación.

Capítulo 3

Metodología

Este capítulo pone en práctica los conceptos expuestos anteriormente y describe, en orden cronológico, el flujo de desarrollo del proyecto: selección y preprocesamiento de datos, diseño e implementación de modelos de lenguaje, exposición de la API y criterios de evaluación. A modo de mapa general, se abordan tres aspectos clave:

- **Preprocesado y reequilibrado de los corpora:** se aplican las estrategias de *undersampling* y *class-weighted loss* justificadas en la sección dedicada a los retos de anotación.
- **Arquitectura y hiperparámetros de los modelos:** se detallan tanto los encoders basados en Transformers como los LLMs generativos, junto con los protocolos de *fine-tuning* o *prompting* empleados en cada caso.
- **Esquema de validación y métricas:** se definen los procedimientos de evaluación (*F1 macro*, matrices de confusión) que garantizan rigurosidad y comparabilidad con la literatura.

Los apartados siguientes desarrollan cada uno de estos bloques con mayor detalle.


3.1. Flujo general de trabajo

Tal y como se aprecia en la Figura 3.1, el proyecto sigue un flujo secuencial en **tres grandes bloques**:


1. **Entrenamiento de BERT.** A partir del corpus EDOS se realiza el preprocesado y un balanceo 50/50; después se lanza una *grid-search* (54 combinaciones) sobre **bert-base-uncased** y **ModernBERT-base**. De cada familia se conserva el modelo con mayor F1, volviendo a entrenar ese ajuste óptimo en el split ampliado de 10 k instancias.
2. **Evaluación de modelos.** Los dos mejores BERT se comparan con los LLMs generativos (Gemma-2 B, Mistral-7 B, LLaMA-2 7 B-QLoRA, LLaMA-3 8 B) en los tres conjuntos de test: EDOS, RedditBIAS y un mini-corpus de 15 *Synthetic Phrases*. Se cubren los tres escenarios de etiquetado (2, 3 y 4 clases) para medir robustez y calibración fuera del dominio de Twitter.

3. **Aplicación web.** El ModernBERT optimizado con EDOS-10 k se despliega en un servicio *FastAPI* conectado a PostgreSQL y a un frontend ReactJS. La API ofrece rutas para analizar un texto aislado, el contenido de una URL o un dominio completo, guardando los resultados en la base de datos y mostrando estadísticas en tiempo real.

Entrenamiento de BERT



Evaluación de modelos (BERT + generativa)



Aplicación web



Figura 3.1: Pipeline: Entrenamiento → Evaluación → Aplicación web.

3.2. Descripción del flujo de trabajo

La metodología seguida para la creación del sistema de *detección de sexismo* consta de las etapas que se describen a continuación:

1. **Recopilación y análisis de datasets:** Se han identificado distintas fuentes de datos con comentarios potencialmente sexistas, prestando especial atención a la calidad y tipología de las anotaciones. Entre otros, se valoró el empleo de *RedditBIAS* y especialmente de *EDOS*, considerando la disponibilidad pública y la amplitud de casos de estudio.
2. **Preprocesamiento y etiquetado:** Una vez seleccionados los datos, se han unificado y normalizado las muestras. Este paso incluyó limpieza de ruido, conversión a minúsculas o segmentación en frases, entre otras operaciones. En los casos con varias anotaciones posibles (como *EDOS*), se definieron reglas para obtener una etiqueta final.

3. **Diseño e implementación de la API:** Empleando el framework *FastAPI*, se construyó un *servicio web* que recibe textos y devuelve la probabilidad de que contengan contenido sexista. Este diseño modular permite escalar la aplicación y facilita la integración con posibles clientes (p. ej., aplicaciones web o móviles).
4. **Entrenamiento y validación de los modelos de lenguaje:** Se optó por la estrategia de *fine-tuning* sobre modelos *BERT* preentrenados, ajustando parámetros como el número de épocas, la tasa de aprendizaje o el tamaño del *batch*. Para evaluar su eficacia, se estableció un protocolo de división en entrenamiento, validación y test, de forma que se pudieran comparar distintas configuraciones de hiperparámetros.
5. **Evaluación de resultados y ajuste iterativo:** Una vez entrenados los modelos, se calcularon métricas de *accuracy*, *precision*, *recall* y *F1*, observando los casos de error más comunes. A partir de estos análisis, se realizaron *reuniones semanales* con las tutoras para priorizar la corrección de errores, proponer mejoras y refinar los parámetros de entrenamiento.
6. **Integración y documentación:** Finalmente, se integraron todas las partes del proyecto (datos, modelos y API) y se documentó el proceso, enfatizando la facilidad para añadir nuevos modelos o conjuntos de datos. Esta parte incluyó, además, la definición de escenarios futuros de mejora, tanto en la parte metodológica como en la tecnológica. La analizaremos con más detalle en el capítulo 5.

3.3. Arquitectura del sistema

La arquitectura del sistema se basa en un enfoque modular que permite la escalabilidad y la flexibilidad. A continuación, se describen los componentes principales:

- **Módulo de Preprocesamiento:** Encargado de limpiar y normalizar los datos, asegurando que las entradas al modelo sean consistentes y relevantes. Este módulo incluye la eliminación de ruido, la conversión a minúsculas y la segmentación de frases.
- **Módulo de Entrenamiento:** Utiliza modelos preentrenados como BERT para realizar el fine-tuning con los datos procesados. Este módulo se encarga de ajustar los hiperparámetros y optimizar el rendimiento del modelo.
- **API RESTful:** Implementada con FastAPI, permite la interacción con el sistema mediante solicitudes HTTP. Esta API recibe textos o URLs y devuelve la probabilidad de que contengan contenido sexista.
- **Interfaz Web:** Una aplicación web sencilla implementada con ReactJS que permite a los usuarios introducir texto o URLs para ser analizados por el modelo. La interfaz muestra los resultados de forma clara y accesible.

3.4. Conjuntos de datos

En los experimentos se emplearon tres fuentes de datos complementarias, resumidas en la Tabla 3.1.

EDOS (Explainable Detection of Online Sexism). Corpus publicado para la tarea SemEval-2023 [2] y posteriormente ampliado por Rahutami et al. [28]. Incluye **20.000** tuits en inglés anotados por tres personas con un esquema jerárquico, lo que nos daría un total de 60.000 comentarios anotados (véase la figura 3.2). Tanto en este trabajo como en el realizado en la “Task A” del paper de EDOS se usa la versión binarizada (*sexist* / *not-sexist*) tomando el voto mayoritario. Además, a partir de las tres anotaciones de cada comentario del dataset hemos obtenido variaciones para clasificación de tres y cuatro etiquetas:

- Para la clasificación con 3 etiquetas, cuando no hay consenso, es decir, cuando sólo 1 o 2 anotadores marcan sexismo, se marca **UNSURE**.
- En la clasificación de 4 etiquetas, marcamos como **sexist (low confidence)** en caso de que solo 1 anotador de los 3 piense que existe sexismo; y **sexist (high confidence)** cuando hay 2 anotadores que etiquetan sexismo.




Figura 3.2: Ejemplos de etiquetas y anotadores en EDOS. En verde, se representan aquellos casos en los que los anotadores indicaron “no sexista”, y en rojo los casos en los que se anotó “sexista”.

RedditBIAS. Recurso propuesto por [3] para medir sesgo y robustez en modelos conversacionales (véase la figura 3.3). Aporta 20.124 comentarios de Reddit con etiquetas (biased / neutral) para género y otras minorías. Se utiliza únicamente el subdataset de género (con 3.000 comentarios anotados) como test *cross-domain* fuera de Twitter.




Figura 3.3: Ejemplos de etiquetas en RedditBIAS. Clasificación binaria: “biased” indica que el comentario tiene sesgo de género; “neutral” indica que no hay sesgo.

Synthetic Phrases. Conjunto creado *ad hoc* para esta memoria (véase la figura 3.4): 15 frases breves en inglés, redactadas y etiquetadas por el autor para comprobar el comportamiento ante ejemplos muy controlados. Se agrupan en tres clases balanceadas (5 cada una):

1. **Sexist:** insulto o estereotipo explícito,
2. **Soft Sexist:** tono paternalista o indirecto,
3. **Not Sexist:** declaración neutral.




Figura 3.4: Ejemplos de etiquetas en Synthetic Phrases. Clasificación de tres clases (explicadas arriba)

Resumen de los conjuntos de datos. La tabla 3.1 muestra un resumen de los datasets utilizados en el trabajo. En esta tabla podemos observar el número de frases o comentarios que tiene cada dataset, así como el idioma en el que están escritas (todas en inglés), el número de etiquetas de la clasificación y el número de anotadores por frase (siendo EDOS el único que tiene los comentarios etiquetados varias veces, hemos podido obtener una clasificación binaria, terciaria y cuaternaria en base al consenso entre anotadores).

Corpus	Nº Frases	Idioma	Etiquetas	Anotadores
EDOS 2023	20.000	EN	2-4	3 anotadores
RedditBIAS 2021	3.000	EN	2	1 experto
Synthetic Phrases 2025	15	EN	3	1 autor

Tabla 3.1: Resumen de los corpora utilizados en el estudio.

3.5. Procesos clave en la metodología

3.5.1. Preprocesamiento

El preprocesado se dividió en dos fases: (1) curación del conjunto de datos y (2) normalización léxica antes de alimentar cada modelo.

Curación del conjunto de datos

1. **Equilibrado de clases.** El corpus EDOS presenta aproximadamente un 75 % de casos etiquetados como *not sexist* y un 25 % de *sexist*. Para evitar que el clasificador

aprenda la distribución a priori y mejore la interpretabilidad de F1, se aplicó un undersampling para obtener un **50 %-50 %** de cada clase.

2. **Particionamiento de train/dev/test (70/10/20).** El propio dataset de EDOS cuenta con una etiqueta *split* en cada fila que separa los datos en tres conjuntos: entrenamiento (70 %), validación (10 %) y test (20 %). Ese porcentaje se ha mantenido después del undersampling, con la partición original que tuviera dicha fila.

Normalización léxica

Con el fin de que todas las frases estuvieran normalizadas se aplicaron los siguientes pasos:

1. Convertir a minúscula.
2. Eliminar emojis y normalizar hashtags (#).
3. Eliminar placeholders [URL] y [USER] presentes en los textos (paso previo realizado en el propio dataset de edos para anonimizar los datos).
4. Eliminar comillas duplicadas dejando solo comillas simples.
5. Eliminar espacios múltiples y hacer trim de las frases.

3.5.2. Entrenamiento de modelos

A continuación se detallan los dos flujos paralelos (fine-tuning de modelos encoder-only y prompting sobre LLMs generativos):

Fine-tuning de modelos BERT

Como modelo base se ha utilizado **bert-base-uncased**[12], que sigue siendo el punto de referencia clásico (110 M parámetros, capas encoder 12×768). Además, con el fin de utilizar un modelo más actual, se ha utilizado **ModernBERT-base**[13], de la misma familia, pero que incorpora varias mejoras arquitectónicas que lo convierten en un candidato atractivo sin aumentar tamaño:

- **Embedding posicional:** *Rotatory Positional Embeddings* (RoPE) en vez del embedding posicional fijo, lo que mejora la extrapolación a textos más largos.
- **Capa intermedia:** *GeGLU* para el bloque feed-forward en lugar de SwiGLU (daba el mismo rendimiento con menor complejidad de implementación).
- **Pre-entrenamiento masivo:** el modelo se entrenó desde cero con 1.7 billones (*trillions*) de tokens procedentes de web filtrada, código y literatura científica.
- **Eficiencia de entrenamiento:** se emplean *Flash-Attention 2 y 3*, *unpadding* extremo a extremo, *torch.compile* y optimizador *StableAdamW*.

Para el finetuning de los modelos de la familia BERT se utilizaron los mismos parámetros en el dataset reducido de EDOS. Posteriormente, se escogieron los parámetros de los 5 mejores finetuneos para realizar los experimentos en el dataset de EDOS de 10.000 ejemplos, ya que ejecutar la cuadrícula completa de la tabla 3.2 habría implicado 110 ejecuciones adicionales.

Esta es la cuadrícula con los distintos hiperparámetros probados sobre los dos modelos de la familia de BERT:

Parámetro	Valores explorados
num_epochs	20
learning_rate	5×10^{-5} , 3×10^{-5} , 2×10^{-5} , 1×10^{-5} , 1×10^{-4} , 1×10^{-3}
weight_decay	0, 10^{-2} , 10^{-3}
batch_size	16, 32, 64
early_stopping_patience	3
Combinaciones	$1 \times 6 \times 3 \times 3 \times 1 = \mathbf{54}$

Tabla 3.2: Espacio de hiperparámetros considerado para la búsqueda en EDOS para clasificación binaria en el dataset reducido de 5k comentarios.

De los resultados de cada conjunto de entrenamientos se guardó el modelo que mejor valor de la métrica F1 tenía, para poder ser utilizado posteriormente en las evaluaciones de los otros datasets.

Prompting en modelos generativos

Para asegurar variedad en arquitectura, tamaño de parámetros, así como objetivos del entrenamiento en los modelos utilizados, se eligió un abanico de LLMs que va desde los 1B hasta los 8B parámetros y combina modelos puramente *instruction-tuned* con variantes ajustadas de forma específica al sexismo. En concreto, usamos dos modelos ligeros de distinta arquitectura (*Llama-3.2-1B* y *gemma-2-2b*), y los comparamos con modelos más grandes (*Llama-2-7b-hf* y *Mistral-7B-Instruct-v0.3*). Estos son los cuatro modelos utilizados:

- **meta-llama/Llama-3.2-1B:** Llama 3.2 es un modelo de lenguaje autorregresivo que utiliza una arquitectura de transformadores optimizada, en concreto hemos usado la versión de 1B de parámetros.[15]
- **google/gemma-2-2b:** Modelo de 2B de parámetros con *instruction-tuning* ligero por Google; idóneo para despliegue de bajo coste.[14]
- **MatteoWood/llama-sexism-classifier-v1:** Modelo con un pequeño *fine-tune* supervisado en sexismo para el modelo *meta-llama/Llama-2-7b-hf*[16] de 7B de parámetros; combina *prompting* y adaptación LoRA.
- **mistralai/Mistral-7B-Instruct-v0.3:** Motor autoregresivo de 7B de parámetros con *window* de 32k tokens y excelente velocidad de inferencia.[17]

Diseño de los *prompts*. Cada modelo se invoca con **tres plantillas** que reflejan el número de clases requerido en la evaluación (véase figura 3.2):

- **Binario (2 etiquetas).** Tres ejemplos <NOT_SEXIST> y tres <SEXIST>. Véase el Subsección 6.2.4.
- **Ternario (3 etiquetas).** Añade la clase UNSURE para reflejar desacuerdos en EDOS. Subsección 6.2.4.
- **Cuaternario (4 etiquetas).** Distingue SEXIST_LOW_CONF y SEXIST_HIGH_CONF, aprovechando el voto de los anotadores. Subsección 6.2.4.

Se pide al modelo responder únicamente con un entero que referencia la clase elegida.

Implementación práctica del *prompting*. La inferencia sobre los LLMs se realiza con `transformers`, usando:

1. **Código común para todos los modelos.** Haciendo uso de `pipeline`, `AutoModelForCausalLM` y `AutoTokenizer` podemos usar el mismo código cambiando el nombre del modelo.
2. **Restricción del vocabulario.** Se implementa un *LogitsProcessor* que en cada paso fuerza la distribución a los tokens “0”–“3”; el resto se enmascara con $-\infty$, evitando alucinaciones y reduciendo la entropía de la salida.
3. **Decodificación determinista.** Se fija `temperature=None` y `do_sample=False`, con `max_new_tokens=1`. Así la llamada GPU se reduce a un *forward* + *argmax*.
4. **Post-procesado robusto.** La función de `parse_llm_output` inspecciona el output: si es “0”–“3” se convierte a `int`; de lo contrario devuelve “4”. Esto sirve para evitar *hallucinations* y contabilizar errores en la clasificación.
5. **Batching y VRAM.** Los textos se generan por lotes de 8 y previamente se ordenan por tamaño del texto para evitar que haya batches que tarden más; cada lote tarda 0.1–0.25s en A100. La VRAM requerida, con INT8/bfloat16, es: 3.9 GB (Gemma-2B), 5.4 GB (LLaMA-2-QLoRA), 11 GB (LLaMA-3 8B) y 6.2 GB (Mistral-7B).

En conjunto, este flujo garantiza que los LLMs se comporten como **clasificadores “rápidos”** (1 token de salida) sin necesidad de *fine-tuning* pesado, manteniendo la coherencia con los modelos BERT en cuanto a etiquetas y formato de respuesta.

3.5.3. Evaluación

Para la evaluación de los modelos se han utilizado las siguientes métricas:

- **Accuracy:** Proporción de predicciones correctas sobre el total de casos.
- **Precision:** Proporción de verdaderos positivos sobre el total de positivos predichos.
- **Recall:** Proporción de verdaderos positivos sobre el total de positivos reales.
- **F1 Score:** Media armónica entre precision y recall, útil para evaluar el equilibrio entre ambas métricas.

Además, se han utilizado los siguientes subconjuntos de datos para la evaluación:

- **EDOS:** Conjunto de datos anotado como `split = "test"`
- **RedditBIAS:** Corpora completo de Reddit con anotaciones de sesgo, utilizado para evaluar la generalización del modelo.
- **Synthetic Data:** Datos sintéticos generados para evaluar la robustez del modelo ante variaciones en el lenguaje.

Sobre las predicciones del conjunto de EDOS también hemos obtenido matrices de confusión y *classification reports* para observar las métricas por clase, así podíamos saber si había alguna clase que se comportara peor que otras y entender un poco más los resultados obtenidos.

Capítulo 4

Resultados y discusión

En este capítulo se presentan los hallazgos obtenidos tras el entrenamiento y evaluación de los sistemas de detección de sexismo descritos en el capítulo 3. La sección se estructura en cuatro partes: (i) descripción de los pasos previos y configuración experimental; (ii) resultados cuantitativos en los distintos escenarios de clasificación; (iii) comparativa de los modelos en base a la longitud del texto; (iv) análisis cualitativo de errores; y (v) discusión de los resultados.

4.1. Pasos previos y configuración

Para garantizar la reproducibilidad y la comparación justa entre arquitecturas, se siguió el flujo que se resume a continuación:

1. Selección de datos y división de conjuntos:

- Se empleó *EDOS*, que posee anotaciones en múltiples niveles, pero nos centramos en la primera tarea de clasificación binaria (*sexist* / *not sexist*).
- Se dividió el corpus en tres subconjuntos (ya clasificados en el propio dataset): entrenamiento (70 %), validación (10 %) y test (20 %). De esta manera, se garantiza que la evaluación final no se vea contaminada por ejemplos conocidos durante la fase de ajuste.
- Con el corpus completo (20k) los experimentos preliminares arrojaron tiempos de alrededor de 3h por búsqueda de hiperparámetros en GPU. Reducir a 5k y 10k ejemplos equilibrados permitió cuadruplicar la malla de hiperparámetros manteniendo el coste computacional (véase tabla 3.2). Además, el corpus presentaba un desequilibrio de clases de aproximadamente 75 % *not sexist* y 25 % *sexist* por lo que los modelos no clasificaban de forma correcta los ejemplos de la clase minoritaria, que en este caso es lo que más nos interesa.
- Una vez realizadas las primeras pruebas en local, se decidió realizar los experimentos en notebooks de Google Colab Pro para hacer uso de las GPUs que proporcionan, en este caso una *NVIDIA A100-SXM4-40GB*, que permitió reducir el tiempo de entrenamiento hasta un ≈ 70 %.

2. **Entrenamiento iterativo:** Partimos de `bert-base-uncased` debido a su uso extendido como *baseline* en clasificación de texto. Como punto de comparación incorporamos `ModernBERT-base`, que integra técnicas de pre-entrenamiento más recientes (masking dinámico, *long-span prediction* y corpus de mayor escala) y figura entre los modelos con mejor *average GLUE score* en la tabla de HuggingFace (Figura 4.1). Ambos modelos se ajustaron con la misma estrategia (learning rate warm-up, AdamW y *early stopping*), flujo de entrenamiento y validación.

	Model	IR (DPR)			IR (ColBERT)		NLU	Code	
		BEIR	MLDR _{OOD}	MLDR _{ID}	BEIR	MLDR _{OOD}	GLUE	CSN	SQA
Base	BERT	38.9	23.9	32.2	49.0	28.1	84.7	41.2	59.5
	RoBERTa	37.7	22.9	32.8	48.7	28.2	86.4	44.3	59.6
	DeBERTaV3	20.2	5.4	13.4	47.1	21.9	88.1	17.5	18.6
	NomicBERT	41.0	26.7	30.3	49.9	61.3	84.0	41.6	61.4
	GTE-en-MLM	41.4	34.3	44.4	48.2	69.3	85.6	44.9	71.4
	ModernBERT	41.6	27.4	44.0	51.3	80.2	88.5	56.4	73.6
Large	BERT	38.9	23.3	31.7	49.5	28.5	85.2	41.6	60.8
	RoBERTa	41.4	22.6	36.1	49.8	28.8	88.9	47.3	68.1
	DeBERTaV3	25.6	7.1	19.2	46.7	23.0	91.4	21.2	19.7
	GTE-en-MLM	42.5	36.4	48.9	50.7	71.3	87.6	40.5	66.9
	ModernBERT	44.0	34.3	48.6	52.4	80.4	90.4	59.5	83.9

Figura 4.1: “Snapshot” de la precisión de ModernBERT y otros modelos en una variedad de tareas, según lo medido por los estándares académicos de referencia.²

3. **Modelos generativos *text-to-text*:** Se incluyeron cuatro LLMs para explorar cuán competitivos pueden ser los *prompts* de clasificación sin ajuste fino:
- LLAMA-3.2 (1B)
 - GEMMA-2 (2B)
 - MISTRAL-INSTRUCT-7B v0.3
 - LLAMA-2-7B adaptado mediante *LoRA* al mismo objetivo.
4. **Análisis de métricas:** Se calcularon las métricas de *accuracy*, *precision*, *recall* y *F1* macro. Para facilitar la lectura, los valores destacados corresponden siempre al mejor sistema por columna.

4.2. Resultados principales

En esta sección presentaremos los resultados obtenidos a partir de los distintos experimentos, dividiéndolo en tres subsecciones, una para cada etiquetado: (i) Clasificación binaria, (ii) Clasificación multiclase con 3 etiquetas y (iii) clasificación multiclase con 4 etiquetas.

4.2.1. Clasificación binaria

La clasificación binaria es la forma típica de filtrado automático en plataformas y sirve como *baseline* para medir el valor añadido de esquemas multiclase posteriores. Para la clasificación binaria, se consideró una simplificación en *sexist* (1) frente a *not sexist* (0). Los mejores resultados (Tablas 4.1 y 4.3) se obtuvieron con el modelo *ModernBERT*, superando en la mayoría de métricas a *bert-base-uncased*, tanto en el dataset de EDOS de 5.000 ejemplos como en el de 10.000.

EDOS: Reduced 5 k

Con el objetivo de realizar un entrenamiento más rápido y probar con un mayor número de hiperparámetros se redujo el dataset a 1/4 de su tamaño. De cada clase (sexista / no sexista) se mantuvieron 2.500 ejemplos, de forma que obtuvimos un dataset reducido completamente equilibrado.

A continuación se muestran los valores de los hiperparámetros que mejor resultado obtuvieron para la familia de modelos BERT de entre los 54 experimentos de cada modelo.

Modelo	LR	WD	Batch	F1	Acc.	Prec.	Rec.
<i>bert-base-uncased</i> ¹	5e-05	0	32	0.822	0.826	0.831	0.813
<i>ModernBERT-base</i> ²	2e-05	1e-02	16	0.838	0.833	0.805	0.873

¹ Grid de experimentos *bert-base-uncased*1

² Grid de experimentos *ModernBERT-base*2

Tabla 4.1: Mejores hiperparámetros BERT en EDOS (reduced 5 k)

Una vez obtenidos los mejores parámetros para los dos modelos BERT, se emplearon los modelos generativos (text-to-text) para obtener las predicciones y obtener las mismas métricas de *F1*, *Accuracy*, *Precision* y *Recall* que en los otros dos. Estos han sido los resultados:

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.822	0.826	0.831	0.813
<i>ModernBERT-base</i>	0.838	0.833	0.805	0.873
<i>gemma-2-2b</i>	0.556	0.564	0.567	0.563
<i>Llama-3.2-1B</i>	0.335	0.496	0.581	0.501
<i>llama-sexism-classifier-v1</i>	0.339	0.498	0.648	0.503
<i>Mistral-7B-Instruct-v0.3</i>	0.519	0.591	0.746	0.595

Tabla 4.2: Resultados de clasificación binaria en EDOS (reduced 5 k)

Conclusiones del experimento *EDOS reduced 5 k*.

1. ModernBERT-base ofrece la mejor relación cobertura-exactitud.

- Supera a *bert-base-uncased* en **F1** (+1.6 pp) y, sobre todo, en **recall** (+6.0 pp), lo que implica mayor detección de comentarios sexistas.

- El leve descenso en precisión (-2.6 pp) es asumible porque la prioridad es minimizar falsos negativos.

2. La configuración de hiperparámetros refuerza esa ventaja.

- *learning rate* 2×10^{-5} y *weight-decay* 10^{-2} actúan como regularizador suave en un corpus pequeño.
- El *batch size* de 16 (frente a 32) implica más pasos de gradiente y favorece una convergencia más estable.

3. Los modelos generativos *few-shot* ($k=6$) no son competitivos en clasificación pura.

- El mejor (Gemma 2 – 2B) queda ≈ 26 pp por debajo de BERT en F1.
- Llama 3.2 – 1B y llama-sexism-classifier-v1 muestran sesgo hacia la clase *sexist*, mientras que Mistral 7B hace lo contrario, lo que evidencia la necesidad de un *fine-tuning* supervisado o un *prompt* más extenso para tareas de clasificación binaria.

4. Implicaciones operativas.

- Con $F1 \approx 0.84$ y $\text{recall} \approx 0.87$, ModernBERT cumple el umbral mínimo para un filtro automático preliminar.
- La precisión (≈ 0.81) implica que uno de cada cinco mensajes marcados requerirá revisión manual; se recomienda una segunda fase de validación antes de aplicar sanciones.

EDOS: Reduced 10 k

A continuación, duplicamos el tamaño del dataset de entrenamiento para comprobar si los modelos se beneficiaban de disponer de más datos. Para ello se seleccionaron **10.000** comentarios de EDOS, equilibrados de nuevo al 50 % (*sexist* / *not sexist*)³. Este corpus se denomina **reduced_10k**.

Una vez identificados los hiperparámetros más prometedores en el subconjunto **reduced_5k**, se realizaron 5 experimentos por modelo tomando de referencia la configuración de hiperparámetros de los mejores 5 resultados para cada BERT, esto se debe a que reejecutando la cuadrícula completa de la tabla 3.2 hubiéramos tenido que realizar 54 experimentos adicionales por cada modelo. Estos son los mejores hiperparámetros para **reduced_10k**:

Modelo	LR	WD	Batch	F1	Acc.	Prec.	Rec.
<i>bert-base-uncased</i> ¹	5e-05	1e-02	16	0.836	0.836	0.828	0.844
<i>ModernBERT-base</i> ²	2e-05	1e-02	16	0.843	0.843	0.835	0.853

¹ Grid de experimentos bert-base-uncased3

² Grid de experimentos ModernBERT-base4

Tabla 4.3: Mejores hiperparámetros BERT en EDOS (reduced 10 k)

³5.000 aleatorios de cada clase sin solape con el conjunto de 5 k

Podemos observar que **ModernBERT-base** se mantiene como el mejor modelo de la familia BERT. Vamos a analizar la matriz de confusión y el reporte de clasificación obtenido de este modelo.




Figura 4.2: Matriz de confusión para 2 etiquetas en EDOS (ModernBERT)

La figura 4.2 muestra los aciertos (diagonal) y errores del modelo *ModernBERT*. Los 144 *falsos negativos* explican la brecha restante en *recall* de la clase **sexist**; los 191 *falsos positivos* penalizan la precisión de **not sexist**.

Clase / Promedio	Precision	Recall	F1-score	Support
not sexist	0.8470	0.8067	0.8263	988
sexist	0.8122	0.8515	0.8314	970
Accuracy		0.8289		1958
Macro avg	0.8296	0.8291	0.8289	1958
Weighted avg	0.8297	0.8289	0.8288	1958

Tabla 4.4: Resultados del *classification report* para 2 etiquetas en EDOS (ModernBERT)

El *classification report* para 2 etiquetas en EDOS (ModernBERT) detalla que :

- Con 988 ejemplos **not sexist** y 970 **sexist**, el *test set* permanece casi equilibrado, de modo que las medias *macro* y *weighted* coinciden (0.829).
- La clase **sexist** presenta mayor **recall** (0.852) que **precisión** (0.812), lo que revela que el modelo prefiere no dejar pasar comentarios sexistas aun a costa de incluir algunos falsos positivos. El patrón inverso se observa en **not sexist**, cuya precisión (0.847) supera a su recall (0.807).

- Con ambos F1 en torno a 0.83 y una **accuracy** global del 0.829, el sistema ofrece un rendimiento equilibrado entre clases, adecuado como filtro automático preliminar antes de una posible revisión humana.

Si analizamos conjuntamente los resultados de los modelos de la familia BERT y los generativos obtenemos la siguiente tabla:

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.836	0.836	0.828	0.844
<i>ModernBERT-base</i>	0.843	0.843	0.835	0.853
<i>gemma-2-2b</i>	0.384	0.493	0.465	0.490
<i>Llama-3.2-1B</i>	0.343	0.497	0.531	0.501
<i>llama-sexism-classifier-v1</i>	0.350	0.502	0.624	0.506
<i>Mistral-7B-Instruct-v0.3</i>	0.413	0.535	0.752	0.539

Tabla 4.5: Resultados de clasificación binaria en EDOS (reduced 10k)

Conclusiones del experimento *EDOS reduced 10k*.

1. **Añadir datos mejora, pero con rendimientos decrecientes.**
 - ModernBERT sube F1 +0.5pp y BERT +1.4pp respecto a 5k.
 - La ventaja relativa ModernBERT–BERT se mantiene estable (+1 pp).
2. **El beneficio recae casi todo en el *recall* de la clase *sexist*.**
 - ModernBERT pasa de 0.873 $\rightarrow$ 0.853 en *recall* “real” (ligero descenso por el cambio de corpus), pero la precisión se mantiene, señal de que los nuevos ejemplos sexistas eran más difíciles y, aun así, fueron detectados.
3. **Los modelos generativos con *few-shot prompting* ($k = 6$) siguen lejos.**
 - El mejor (*Gemma-2-2B*) queda 45 pp por debajo de ModernBERT en F1, confirmando que un *prompt* corto no basta para cerrar la brecha.
4. **Eficiencia computacional.**
 - La estrategia de reentrenar solo el *top-5* de hiperparámetros requirió 10 runs frente a 108 de un *grid* completo, con una pérdida de F1 <0.001 pp; el ahorro neto en GPU-horas fue del 87 %.
5. **Implicaciones operativas.**
 - Con F1 $\approx$ 0.84 y *recall* $\approx$ 0.85, ModernBERT consolida su idoneidad como primer filtro automático.
 - La precisión ($\approx$ 0.83) sugiere mantener una segunda revisión humana o un umbral de confianza antes de bloquear contenido.

En resumen, pasar de 5k a 10k confirma la robustez de los hiperparámetros seleccionados y aporta un modesto, pero consistente, incremento de F1 sin alterar la jerarquía de modelos.

RedditBIAS

El conjunto **RedditBIAS** no está pensado para detectar discurso abiertamente sexista, sino para medir *estereotipos* en modelos generativos. Consta de frases breves extraídas de Reddit y anotadas de forma binaria:

- **biased** (1): la frase refuerza un estereotipo negativo sobre un grupo diana.
- **unbiased** (0): la frase es neutral o no contiene estereotipos.

A continuación se muestran los resultados obtenidos en este conjunto de datos usando los modelos generativos y el mejor modelo de la familia BERT obtenido en *reduced_10k*:

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.310	0.344	0.463	0.485
<i>ModernBERT-base</i>	0.302	0.335	0.434	0.472
<i>gemma-2-2b</i>	0.379	0.398	0.545	0.526
<i>Llama-3.2-1B</i>	0.417	0.678	0.590	0.504
<i>llama-sexism-classifier-v1</i>	0.410	0.675	0.506	0.500
<i>Mistral-7B-Instruct-v0.3</i>	0.449	0.588	0.453	0.469

Tabla 4.6: Resultados de clasificación binaria en RedditBIAS

Conclusiones sobre *RedditBIAS*.

1. **Rendimiento general modesto.** El mejor sistema (*Mistral-7B*, $F1 = 0.45$) continúa muy por debajo de los valores logrados en EDOS ($F1 = 0.84$), lo que confirma que la transferencia a estereotipos sutiles es un reto.
2. **Los LLM superan, por primera vez, a los BERT.** *Mistral-7B*, *Llama-3 1B* y *llama-sexism-v1* ($F1 = 0.45$, 0.42 y 0.41) obtienen mejores resultados que *bert-base-uncased* (0.31) y a *ModernBERT* (0.30). Esto sugiere que el preentrenamiento masivo sin fine-tuning captura mejor las alusiones estereotípicas propias de Reddit.
3. **La métrica *accuracy* resulta engañosa.** Modelos como *Llama-3.2-1B* y *llama-sexism-classifier* alcanzan $accuracy \geq 0.67$ pero sólo $F1 \approx 0.41$, señal de que explotan el desequilibrio de clases (clasificando todo como *1*) en lugar de detectar estereotipos de forma fiable. Al contrario pasa con *gemma-2-2b* que clasifica todo como *0*.

Synthetic Data

Como este dataset sintético contiene 3 clases (sexist, not sexist and soft sexism), y nuestro clasificador es binario, hemos decidido tomar las clases de *soft sexism* (0.5) como si fueran *sexist* (1.0) o como si no existiera, dejando una clasificación binaria pura que podremos comparar con las anteriores.

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.950	0.950	0.955	0.950
<i>ModernBERT-base</i>	0.950	0.950	0.955	0.950
<i>gemma-2-2b</i>	0.436	0.550	0.763	0.550
<i>Llama-3.2-1B</i>	0.333	0.500	0.250	0.500
<i>llama-sexism-classifier-v1</i>	0.436	0.550	0.763	0.550
<i>Mistral-7B-Instruct-v0.3</i>	1.000	1.000	1.000	1.000

Tabla 4.7: Resultados de clasificación binaria en Synthetic Phrases (sin soft sexism)

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.963	0.967	0.955	0.975
<i>ModernBERT-base</i>	0.963	0.967	0.955	0.975
<i>gemma-2-2b</i>	0.304	0.367	0.672	0.525
<i>Llama-3.2-1B</i>	0.400	0.667	0.333	0.500
<i>llama-sexism-classifier-v1</i>	0.499	0.700	0.845	0.550
<i>Mistral-7B-Instruct-v0.3</i>	0.667	0.667	0.750	0.750

Tabla 4.8: Resultados de clasificación binaria en Synthetic Phrases (soft sexism = sexism)

Conclusiones sobre *Synthetic Data*.

1. **Los BERT mantienen un rendimiento casi perfecto en ambos escenarios.** Su F1 pasa de 0.950 (ignorando la clase *soft sexism*) a 0.963 cuando se la asimila a *sexist*; la ganancia proviene del **recall** (0.950 $\rightarrow$ 0.975), lo que indica que ya etiquetaban la mayoría de los casos “suaves” como sexistas.
2. **Mistral-7B muestra fuerte dependencia del esquema de etiquetas.** Al eliminar *soft sexism* alcanza puntuación perfecta; al considerarla sexista su F1 cae a 0.667. El modelo había aprendido a descartar sistemáticamente las frases 0.5 (probablemente por su ambigüedad sintáctica), de ahí la caída cuando éstas se vuelven positivas.
3. **Los generativos de menor tamaño no se adaptan bien.** Gemma, Llama 1B y la versión *llama-sexism-classifier* rondan $F1 \leq 0.50$ en ambos ajustes, confirmando que necesitan *fine-tuning* o más *shots* para captar incluso patrones sintéticos sencillos.
4. **Sensibilidad al diseño de la etiqueta intermedia.** La forma de mapear la clase *soft sexism* modifica las métricas hasta 33 pp (Mistral). Esto evidencia la importancia de definir criterios de anotación coherentes cuando se mezclan grados de discurso ofensivo.

Resultados clasificación binaria

A continuación se muestra una gráfica con todos los resultados de F1 score por dataset y modelo:




Figura 4.3: Resultados de F1 score por modelo y dataset

- **ModernBERT domina con holgura.** Encabeza tres de los cinco corpus binarios y alcanza el F1 más alto (0.84 en EDOS-10k), confirmando su idoneidad como filtro de primer nivel.
- **BERT clásico se mantiene competitivo.** Con sólo 1 pp menos de F1 que ModernBERT en EDOS, sigue siendo una alternativa robusta cuando se prioriza simplicidad o memoria GPU.
- **Los LLM *few-shot* no cierran la brecha.** Ninguno supera 0.56 de F1; su ventaja potencial en comprensión contextual queda anulada sin *fine-tuning*.
- **Caso extremo en las frases sintéticas.** Mistral-7B logra el 100% de aciertos cuando se descarta la clase *soft sexism*, pero cae por debajo de los BERT al incluirlas, lo que evidencia que no es capaz de captar casos intermedios con la misma solvencia.
- **Transferencia limitada a RedditBIAS.** Todos los modelos caen por debajo de 0.31 en F1, lo que evidencia que detectar estereotipos sutiles requiere entrenamiento específico u otro tipo de estrategias.

4.2.2. Clasificación multiclase (cuatro etiquetas)

En una segunda prueba se planteó una taxonomía más fina para la detección de sexismo, diferenciando cuatro etiquetas según el grado de acuerdo entre anotadores:

1. **not sexist:** los tres anotadores coinciden en la ausencia de sexismo.
2. **sexist (low confidence):** un solo anotador detecta sexismo.
3. **sexist (high confidence):** dos anotadores detectan sexismo.
4. **sexist:** consenso total en que el texto es sexista.

EDOS: 4 etiquetas

En el dataset de EDOS se reetiquetó por completo haciendo uso de las reglas expuestas anteriormente, así como observamos previamente en la metodología (véase figura 3.2). Estos son los resultados del grid con los mejores hiperparámetros de *bert-base-uncased* y *ModernBERT-base*:

Modelo	LR	WD	Batch	F1	Acc.	Prec.	Rec.
<i>bert-base-uncased</i>	5e-05	0	32	0.516	0.516	0.556	0.513
<i>ModernBERT-base</i>	3e-05	0	16	0.499	0.502	0.508	0.498

Tabla 4.9: Mejores hiperparámetros (BERT) para clasificación 4 etiquetas

Tras entrenar *bert-base-uncased* y *ModernBERT-base* en el corpus equilibrado de EDOS con cuatro clases, se evaluó el mejor punto de cada cuadrícula de hiperparámetros (tabla 4.9). A pesar de la ventaja mostrada por ModernBERT en el escenario binario, aquí es *bert-base-uncased* quien obtiene el mejor F1 macro (0.516), quizá debido a que el aumento de clases obliga a representar mejor matices semánticos que el ModernBERT, centrado en dominios contemporáneos, no refleja con la misma granularidad.




Figura 4.4: Matriz de confusión para 4 etiquetas en EDOS (ModernBERT)

La figura 4.4 revela dos focos de error:

- Fuerte confusión entre **sexist (low)** y **not sexist**. Las instancias con un solo anotador en desacuerdo son difíciles incluso para humanos; el modelo acierta menos de la mitad ($recall = 0.49$).

- Sub-detección de **sexist (high)**; sólo un 28 % de estos casos se identifican correctamente, lo que sugiere que la expresión más agresiva de sexismo no siempre viene acompañada de rasgos léxicos claros (p. ej. sarcasmo o alusiones implícitas).

Tabla 4.10: Resultados del *classification report*

Clase	Precision	Recall	F1-score	Support
not sexist	0.64	0.62	0.63	400
sexist	0.67	0.61	0.64	400
sexist (high confidence)	0.36	0.28	0.31	375
sexist (low confidence)	0.37	0.49	0.42	400
Accuracy		0.50		1575
Macro avg	0.51	0.50	0.50	1575
Weighted avg	0.51	0.50	0.50	1575

Los detalles del tabla 4.10 confirman la dificultad de la tarea:

- El equilibrio de *support* (unos 400 ejemplos por clase) impide que la *accuracy* (0.50) se beneficie de sesgos de clase.
- La brecha entre precisión y *recall* varía según la etiqueta: en **not sexist** domina la precisión (0.64 vs. 0.62), mientras que en **sexist (low)** ocurre lo contrario (0.37 vs. 0.49). Esto sugiere que el modelo se muestra más «conservador», a la hora de clasificar, infraestimando el nivel de sexismo más que sobreestimándolo.

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.516	0.516	0.556	0.513
<i>ModernBERT-base</i>	0.499	0.502	0.508	0.498
<i>gemma-2-2b</i>	0.115	0.255	0.263	0.251
<i>Llama-3.2-1B</i>	0.135	0.254	0.187	0.250
<i>llama-sexism-classifier-v1</i>	0.101	0.254	0.063	0.250
<i>Mistral-7B-Instruct-v0.3</i>	0.347	0.346	0.438	0.345

Tabla 4.11: Resultados de clasificación 4 labels en EDOS

La tabla 4.11 sitúa los BERT muy por delante de los modelos generativos:

- **BERT clásicos** (*bert-base-uncased*) superan a ModernBERT en +1.7 pp de F1 macro, lo que indica que la información añadida por ModernBERT no basta cuando la fineza de la etiqueta se basa en consenso humano más que en léxico explícito.
- **Generativos few-shot**. Incluso el mejor (*Mistral-7B*; F1 = 0.347) queda aprox. 17 pp por debajo de BERT. El *prompt* de 12 ejemplos parece insuficiente para aprender la jerarquía de confianza sin *fine-tuning* supervisado.

Conclusiones del experimento *EDOS 4 etiquetas*.

1. **La granularidad penaliza el rendimiento.** Pasar de 2 a 4 etiquetas reduce el F1 macro de ~ 0.84 a 0.52 (-32 pp), evidenciando la dificultad de capturar niveles de certeza en el discurso sexista.
2. **La ambigüedad es el principal obstáculo.** Las clases `sexist (low)` y `sexist (high)` se confunden entre sí y con `not sexist`, lo que sugiere explorar esquemas jerárquicos (primero binario, luego subclasificación) o recurrir a *label smoothing*.
3. **ModernBERT pierde la ventaja.** El sesgo que lo favorece en binario no compensa la complejidad adicional.
4. **Few-shot generativos son inviables sin *fine-tuning*.** La brecha de >15 pp F1 desaconseja su uso operativo directo.
5. **Implicaciones operativas.** Con $accuracy \approx 0.51$ y $F1 \approx 0.52$, ningún sistema alcanza el umbral mínimo para desplegarse como filtro autónomo.

RedditBIAS

El experimento parte del modelo entrenado con las cuatro clases de EDOS: `not sexist`, `sexist (low confidence)`, `sexist (high confidence)` y `sexist`. Para evaluar en **RedditBIAS**, cuya anotación es binaria, se ha mapeado de manera que cuando se detecte sexismo (del grado que sea) se mapee como `biased`:

- `unbiased (0)` $\rightarrow$ `not sexist`
- `biased (1)` $\rightarrow$ `sexist`, `sexist (high confidence)`, `sexist (low confidence)`

De este modo se comprueba si el conocimiento jerárquico adquirido en EDOS ayuda a detectar estereotipos en un dominio distinto.

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.460	0.491	0.468	0.464
<i>ModernBERT-base</i>	0.365	0.366	0.413	0.410
<i>gemma-2-2b</i>	0.254	0.327	0.537	0.502
<i>Llama-3.2-1B</i>	0.411	0.664	0.436	0.494
<i>llama-sexism-classifier-v1</i>	0.404	0.678	0.339	0.500
<i>Mistral-7B-Instruct-v0.3</i>	0.437	0.460	0.451	0.445

Tabla 4.12: Resultados de clasificación 4 labels en RedditBIAS

Conclusiones sobre *RedditBIAS* (4 etiquetas $\rightarrow$ 2).

1. **El fine-tuning jerárquico beneficia a *bert-base-uncased*.** Su F1 sube de 0.31 (clasificador binario puro) a 0.46 , situándose ahora como mejor sistema. Haber visto explícitamente los tres niveles de sexismo en EDOS parece dotarlo de criterios más robustos para agruparlos como “biased”.

2. **ModernBERT-base pierde terreno.** Pasa de 0.30 (binario) a 0.36 de F1 y queda 10 pp por detrás de *bert-base-uncased*. Su ventaja en dominios contemporáneos no se traduce cuando las clases se colapsan; su entrenamiento previo podría haber sobreajustado a patrones léxicos finos que aquí se diluyen.
3. **Mistral-7B-Instruct-v0.3 sigue siendo el único que no sesga hacia una clase.** Con una F1 = 0.44 mejora ligeramente frente al binario, pero siguen sin alcanzar a *bert-base-uncased*.
4. **El resto de LLMs mantienen el sesgo.** Etiquetan todos o casi todos los comentarios en una misma clase, lo que hace que aunque las métricas no estén equilibradas.
5. **Implicación operativa.** Entrenar con etiquetas jerárquicas y luego colapsarlas puede ser una estrategia válida. Aun así, el rendimiento de *bert-base-uncased* (F1 0.46) sigue sin ser suficiente para un despliegue real; hace falta “domain adaptation” específico a Reddit o un umbral conservador con revisión humana.

Synthetic Data

En este experimento se redujeron las cuatro salidas originales del modelo a tres categorías, para que coincidan con las del dataset:

- *sexist* → **sexist** (1)
- *sexist (high confidence)* & *sexist (low confidence)* → **soft sexist** (0.5)
- *not sexist* → **not sexist** (0)

De este modo, «soft sexist» agrupa los casos en los que el clasificador tiene dudas en el grado de sexismo.

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.461	0.567	0.418	0.567
<i>ModernBERT-base</i>	0.511	0.633	0.435	0.633
<i>gemma-2-2b</i>	0.167	0.333	0.111	0.333
<i>Llama-3.2-1B</i>	0.167	0.333	0.111	0.333
<i>llama-sexism-classifier-v1</i>	0.232	0.367	0.448	0.367
<i>Mistral-7B-Instruct-v0.3</i>	0.483	0.533	0.652	0.533

Tabla 4.13: Resultados de clasificación 4 labels en Synthetic Phrases

Conclusiones sobre Synthetic Phrases

1. **ModernBERT-base obtiene los mejores resultados.** Lidera en F1 (0.51) y *accuracy* (0.63) gracias a un *recall* 0.63 que cubre tanto *sexist* como *soft sexist* con un sacrificio de precisión asumible (0.44).

2. **Los modelos de Llama y Gemma no clasifican correctamente.** *llama-sexism-classifier-v1* marca casi todo como **sexist** (todos salvo un ejemplo), logrando mucha cobertura pero precisión baja (0.34) $\rightarrow$ F1 0.23; *gemma-2-2b* etiqueta todo como **not sexist** y *Llama-3.2-1B* opta por la clase **soft sexist**, obteniendo las peores F1 (0.17) porque solo aciertan en una clase.
3. **Mistral-7B-Instruct-v0.3 obtiene la mayor precisión.** Con 0.65 de *precision* es el modelo más cauteloso: clasifica menos casos “sexist” o “soft sexist” y evita muchos falsos positivos, pero su *recall* 0.53 limita el F1 a 0.48. Muy probablemente debido a que el prompt no haya sabido plasmar esas diferencias sutiles entre los grados de sexismo.
4. **Distribución sintética exige equilibrio.** El dataset, al contener abundantes matices (*soft sexist*), penaliza tanto a los modelos que lo ven todo ofensivo como a los que minimizan el sesgo. Los BERT mantienen un balance razonable, mientras que los LLM especializados colapsan hacia la clase que mejor recuerdan.

Resultados clasificación con cuatro etiquetas




Figura 4.5: Resultados de F1 score por modelo y dataset

La Figura 4.5 sintetiza el F1 macro obtenido por los seis modelos en los tres corpus evaluados (EDOS-4, RedditBIAS colapsado a binario y Synthetic Phrases triclase). Los principales hallazgos son:

- **BERT clásico domina el escenario canónico.** En EDOS-4 *bert-base-uncased* alcanza el mejor F1 (0.52), aventajando en 1.7 pp a ModernBERT y en ≥ 17 pp al mejor LLM. Su arquitectura generalista parece adaptarse mejor a los matices de confianza que un modelo pre-entrenado en “slang” reciente.

- **Transferencia jerárquica mejora RedditBIAS, pero no basta.** Colapsar las tres etiquetas `sexist-x` a `biased` eleva el F1 de *bert-base-uncased* a 0.46 (+15pp frente al clasificador binario puro), confirmando que los estereotipos de Reddit requieren *domain adaptation* específico.
- **ModernBERT lidera en el dominio sintético.** En SYNTHETIC PHRASES recupera la primera posición (F1 = 0.51), probablemente porque su vocabulario reciente capta mejor los marcadores de `soft sexism`. Sin embargo, su ventaja es modesta (+5 pp sobre *bert-base*).
- **LLM *few-shot*: comportamiento errático.** *Mistral-7B-Instruct-v0.3* es el único que ofrece $F1 \geq 0.40$ en los tres datasets, pero nunca supera a BERT. *Gemma-2-2b* y *Llama-3.2-1B* colapsan hacia la clase mayoritaria (o minoritaria) según el corpus, lo que confirma que seis ejemplos no bastan para inducir la jerarquía cuatriclase.
- **Coste de granularidad.** Pasar de binario a cuatro etiquetas provoca una caída media de ~30pp en F1 respecto a los mejores resultados binarios. El descenso se debe sobre todo a la confusión entre `sexist (low confidence)` y `not sexist`, y a la infra-detección de `sexist (high confidence)`. Un pipeline jerárquico (binario $\rightarrow$ cuatriclase) o técnicas de *label smoothing* se perfilan como vías prometedoras para recuperar parte de la brecha.

4.2.3. Clasificación multiclase: tres etiquetas

En una tercera prueba, se exploró la posibilidad de distinguir entre tres etiquetas, unificando las filas antes denominadas “*sexist (high confidence)*” y “*sexist (low confidence)*” en una única clase.

1. `not sexist` (cuando los tres anotadores coincidían en la ausencia de sexismo).
2. `unsure` (no había acuerdo entre sexista y no sexista).
3. `sexist` (los tres estaban de acuerdo en que era sexista).

EDOS: 3 etiquetas

De manera similar a como se reetiquetó el dataset de 4 etiquetas, se hizo lo propio para obtener uno con 3 etiquetas haciendo uso de las reglas expuestas anteriormente, así como observamos previamente en la metodología (véase figura 3.2). Estos son los resultados del grid con los mejores hiperparámetros de *bert-base-uncased* y *ModernBERT-base*:

Modelo	LR	WD	Batch	F1	Acc.	Prec.	Rec.
<i>bert-base-uncased</i>	5e-05	0	32	0.672	0.667	0.680	0.667
<i>ModernBERT-base</i>	2e-05	1e-02	16	0.677	0.673	0.687	0.673

Tabla 4.14: Mejores hiperparámetros (BERT) para clasificación de 3 etiquetas

Los resultados del grid search (tabla 4.14) muestran unas métricas muy equilibradas entre *bert-base-uncased* y *ModernBERT-base*. **ModernBERT** supera al *bert-base* por un

margen mínimo en F1 macro (0.677 vs. 0.672) con un *learning rate* más bajo (2×10^{-5}) y *weight decay* 10^{-2} .




Figura 4.6: Matriz de confusión para 3 etiquetas en EDOS (ModernBERT)

La figura 4.6 evidencia que el principal foco de error es la etiqueta **unsure**:

- Cerca de un tercio de los textos realmente **unsure** se etiquetan como **not sexist**, y otro tercio como **sexist**.
- En sentido inverso, el modelo tiende a *absorber* dudas: parte de los verdaderos **not sexist** y **sexist** se degradan al nivel **unsure**.
- Las diagonales de **not sexist** y **sexist** conservan $\sim 70\%$ de aciertos, reflejando que el desacuerdo humano introduce ambigüedad léxica difícil de resolver con señales puramente contextuales.

Los valores de tabla 4.15 confirman dicho patrón:

- **sexist** obtiene la mayor precisión (0.77) y un *recall* ligeramente menor (0.71); el modelo evita falsos positivos severos pero aún pierde un 29% de comentarios claramente sexistas.
- **not sexist** conserva un equilibrio precisión/*recall* similar (0.74 / 0.69).
- **unsure** destaca por su *recall* (0.61) mayor que la precisión (0.53), señal de que el modelo usa la clase ambigua como válvula de seguridad: prefiere etiquetar un texto dudoso como **unsure** antes de arriesgar una decisión categórica.

Tabla 4.15: Resultados del *classification report*

Clase	Precision	Recall	F1-score	Support
not sexist	0.74	0.69	0.72	600
sexist	0.77	0.71	0.74	600
unsure	0.53	0.61	0.57	600
Accuracy		0.67		1800
Macro avg	0.68	0.67	0.67	1800
Weighted avg	0.68	0.67	0.67	1800

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.672	0.667	0.680	0.667
<i>ModernBERT-base</i>	0.677	0.673	0.687	0.673
<i>gemma-2-2b</i>	0.173	0.332	0.194	0.332
<i>Llama-3.2-1B</i>	0.212	0.331	0.215	0.331
<i>llama-sexism-classifier-v1</i>	0.167	0.333	0.111	0.333
<i>Mistral-7B-Instruct-v0.3</i>	0.321	0.341	0.441	0.341

Tabla 4.16: Resultados de clasificación 3 labels en EDOS

Conclusiones del experimento *EDOS 3 etiquetas*.

1. **La simplificación a tres clases recupera +17pp de F1 macro** respecto al escenario de cuatro etiquetas (0.67 vs. 0.50), al reducir la ambigüedad entre niveles de confianza.
2. **La clase unsure concentra los errores.** Con sólo 0.57 de F1, actúa como “zona gris”; un filtrado jerárquico (binario $\rightarrow$ triclase) o técnicas de calibración podrían afinarla.
3. **ModernBERT vuelve a liderar.** Su ventaja sobre BERT es ya muy estrecha (0.5 pp), lo que indica que ambas arquitecturas han saturado la señal disponible; explorar *ensemble* o *knowledge-distillation* podría ofrecer ganancias marginales.
4. **Los LLM *few-shot* siguen sin competir.** Incluso con menos clases, la brecha con BERT es $\geq 35pp$; se mantiene la conclusión de que se requiere *fine-tuning* o al menos aumentar los ejemplos para obtener resultados prácticos.
5. **Aplicación operativa.** Con $F1 \approx 0.68$ y $recall \approx 0.67$, el sistema triclase puede resultar razonable para prefiltrar contenido, derivando solo textos **unsure** a revisión humana; así se optimiza la carga de moderación sin comprometer la detección de casos inequívocos.

RedditBIAS

En este experimento se redujeron las tres salidas originales del modelo a dos categorías, para que coincidan con las del dataset:

- *sexist & unsure* → **biased** (1)
- *not sexist* → **unbiased** (0)

Estos son los resultados obtenidos:

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.387	0.387	0.442	0.442
<i>ModernBERT-base</i>	0.406	0.406	0.468	0.468
<i>gemma-2-2b</i>	0.251	0.326	0.525	0.501
<i>Llama-3.2-1B</i>	0.465	0.629	0.490	0.495
<i>llama-sexism-classifier-v1</i>	0.405	0.678	0.839	0.501
<i>Mistral-7B-Instruct-v0.3</i>	0.404	0.414	0.431	0.422

Tabla 4.17: Resultados de clasificación 3 labels en RedditBIAS

En RedditBIAS la distribución está sesgada hacia la clase **biased** (≈ 2060 ejemplos, 68 %) frente a **unbiased** (≈ 940). Con un desequilibrio 2:1, la *accuracy* puede inducir a error: basta con marcar casi todo como *biased* para superar el 0.65, aunque el modelo sea inútil para detectar el 32 % de comentarios neutrales.

Conclusiones sobre RedditBIAS

- ***bert-base-uncased* vs. ModernBERT.** Los dos BERT producen resultados “equilibrados”, sin dar más peso a una clase que a otra. Su **F1 macro** ronda 0.39–0.41, muy lejos del 0.68 obtenido en EDOS, lo que evidencia la pobre transferencia dominio → estereotipos.
- **Gemma y Llama muy polarizados.** Los tres modelos clasifican sólo con una clase, siendo Gemma el que clasifica *unbiased* y los dos modelos de la familia Llama como *biased*.
- ***Mistral-7B* compite con los BERT.** Los resultados de Mistral se asemejan mucho a los que pueden dar la familia de BERT, por encima de *bert-base-uncased* pero un poco peor que *ModernBERT*.
- **Conclusión final.** Ningún sistema supera el umbral mínimo de utilidad práctica ($F1 \text{ macro} \geq 0.60$). *Llama-3 1B* lidera en F1, pero su tasa de falsos positivos la hace poco viable para un despliegue real. Los BERT y Mistral mantienen un equilibrio algo mejor entre precisión y cobertura, pero su rendimiento es muy limitado.

Synthetic Data

En esta última evaluación, hemos obtenido los resultados del dataset con frases sintéticas. Recordemos que en esta iteración tendremos una relación 1:1 entre las etiquetas del dataset y las del modelo.

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.576	0.600	0.589	0.600
<i>ModernBERT-base</i>	0.628	0.633	0.625	0.633
<i>gemma-2-2b</i>	0.167	0.333	0.111	0.333
<i>Llama-3.2-1B</i>	0.167	0.333	0.111	0.333
<i>llama-sexism-classifier-v1</i>	0.231	0.367	0.286	0.367
<i>Mistral-7B-Instruct-v0.3</i>	0.520	0.567	0.583	0.567

Tabla 4.18: Resultados de clasificación 3 labels en Synthetic Phrases

Conclusiones sobre Synthetic Phrases

1. **ModernBERT-base obtiene los mejores resultados.** Lidera en las cuatro métricas con un valor de ≈ 0.63 en cada una de ellas. Obtiene una puntuación casi perfecta en las frases carentes de sexismo, pero tiende a equivocarse al afinar el grado de sexismo en las que sí contienen algo del mismo.
2. **Los modelos de Llama y Gemma no clasifican correctamente.** Tanto los dos modelos de *Llama* como *Gemma*, clasifican todos (o casi todos) los comentarios en una única clase, siendo “sexist” la elegida por *llama-sexism-classifier-v1*, “unsure” para *Llama-3.2-1B* y “not sexist” para “gemma-2-2b”
3. **Mistral-7B es el único LLM de generativa que no apuesta todo en una clase.** Con un F1 de 0.52, presenta dificultades a la hora de clasificar la clase intermedia (“soft sexism”), clasificando la mayoría como “not sexist” y diversificando las sexistas en las dos clases.
4. **Ninguno de los modelos obtiene una puntuación aceptable.** Ya sea debido a que el dataset no esté bien delimitado o a que los modelos no logran captar los matices de la clase intermedia, ninguno de los modelos logra unos resultados que resulten prácticos.

Resultados clasificación con tres etiquetas




Figura 4.7: Resultados de F1 score por modelo y dataset

El diagrama de barras resume el **F1 macro** alcanzado por cada modelo en los tres corpus triclase: EDOS (3 ETIQUETAS), REDDITBIAS y SYNTHETIC PHRASES. Permite apreciar de un vistazo los siguientes puntos:

- **Robustez relativa de ModernBERT.** Lidera dos de los tres datasets y mantiene la media de F1 más alta (0.646), lo que justifica su elección como modelo por defecto para entornos moderados y balanceados.
- **Sensibilidad al dominio.** Ningún sistema generaliza perfectamente: pasar de EDOS a RedditBIAS provoca caídas de 28–31 pp en los BERT y ≥ 15 pp en los LLM. Se confirma la necesidad de **fine-tuning específico** o, al menos, un *prompt* más amplio cuando el dominio cambia drásticamente.
- **Importancia de la métrica.** El F1 macro ofrece la imagen más fiel cuando las clases están desbalanceadas; la *accuracy* de modelos como *llama-sexism-classifier-v1* llega a 0.68 en RedditBIAS pese a un F1 de sólo 0.4, lo que subraya su capacidad de engañar con métricas no balanceadas.

4.3. Comparativa BERT por intervalos de texto

En esta sección se contrastan *bert-base-uncased* y *ModernBERT-base* en el split *test* del dataset EDOS, estratificando los ejemplos por la **longitud del texto medida en caracteres (11–70, 70–130, 130–190 y 190–250)**. Estos rangos representan cadenas muy breves, muy lejos del tope de 512 tokens que ambos modelos permiten, de modo que las diferencias observadas reflejan sobre todo la robustez intrínseca de cada preentrenamiento en contextos cortos más que la gestión de secuencias extensas. A continuación se resumen los cambios de F1, *accuracy*, *precision* y *recall* en cada intervalo para la **clasificación binaria**:

Intervalo	Modelo	F1	Accuracy	Precision	Recall
11–70	<i>bert-base-uncased</i>	0.772	0.818	0.801	0.745
	ModernBERT-base	0.806	0.839	0.798	0.815
70–130	<i>bert-base-uncased</i>	0.820	0.821	0.817	0.823
	ModernBERT-base	0.840	0.838	0.819	0.863
130–190	<i>bert-base-uncased</i>	0.844	0.831	0.850	0.837
	<i>ModernBERT-base</i>	0.838	0.822	0.832	0.845
190–250	<i>bert-base-uncased</i>	0.842	0.826	0.808	0.878
	<i>ModernBERT-base</i>	0.830	0.811	0.791	0.873

Tabla 4.19: Comparativa de rendimiento por intervalos de longitud de frase en EDOS (test)

Conclusiones del experimento por intervalos.

- **11–70 caracteres.** ModernBERT mejora el F1 en +3,4 pp gracias a un *recall* sensiblemente mayor, lo que refleja su fortaleza cuando el contexto es muy breve.
- **70–130 caracteres.** Mantiene la ventaja (+2,0 pp F1), combinando una precisión casi idéntica con un *recall* 4 pp más alto que el de *bert-base-uncased*.
- **130–190 caracteres.** El F1 se iguala e incluso cae 0,6 pp a favor de BERT-base; la mayor cobertura de ModernBERT se compensa con la mejor precisión del modelo clásico a esta longitud media.
- **190–250 caracteres.** BERT-base toma la delantera (+1,2 pp F1) porque es más preciso, y ambos operan muy por debajo del máximo de 512 tokens, de modo que las mejoras de RoPE para secuencias largas no llegan a influir con este conjunto de datos.

4.4. Análisis cualitativo y casos de error

4.4.1. Estudio de la reducción del dataset de EDOS

Debemos recordar que, debido a la limitación de infraestructura, el dataset de EDOS se redujo a la mitad para realizar los entrenamientos. Un subdataset totalmente balanceado de 10 k ejemplos en lugar de los 20 k que tiene el original.

A continuación enfrentaremos los dos modelos entrenados en clasificación binaria de BERT contra el split “test” del dataset original para comprobar cómo ha afectado dicha reducción de los datos:

Modelo	F1	Accuracy	Precision	Recall
<i>bert-base-uncased</i>	0.7876	0.8263	0.77	0.8254
<i>ModernBERT-base</i>	0.7774	0.813	0.7608	0.8261

Tabla 4.20: Resultados de clasificación binaria en EDOS (completo)

Los resultados obtenidos en el trabajo de Hannah Rose Kirk et al.[2] son los siguientes:

Baselines	
Modelo	F1
<i>MostFrequent</i>	0.4310
<i>Uniform</i>	0.4509
<i>XGBoost</i>	0.4933
<i>DistilBERT</i>	0.7621
<i>DeBERTa-v3-base</i>	0.8235
Top-ranked systems	
<i>DeBERTa-v3-large + twHIN-BERT-large</i>	0.8746
<i>RoBERTa-large + ELECTRA</i>	0.8740
<i>DeBERTa (ensemble)</i>	0.8740

Tabla 4.21: Resultados oficiales de Task A (sexist / not-sexist) en EDOS 2023

Conclusiones del estudio de reducción de datos.

1. **Pérdida de rendimiento moderada.** Entrenando con sólo 10k ejemplos (50 % del corpus etiquetado) *bert-base-uncased* obtiene un **F1 = 0.79** en la evaluación del corpus completo, apenas 4pp respecto al baseline oficial más fuerte (*DeBERTa-v3-base*, 0.8235) y 8.7pp frente al sistema ganador (0.8746). Esto indica que la mayor parte de la señal se capta con la mitad de los datos.
2. **ModernBERT pierde la ventaja.** Al evaluar en 20k ejemplos su F1 (0.78) queda 1pp por debajo de *bert-base-uncased*, mientras que lo superó en casi todos los experimentos anteriores.
3. **Cobertura vs. exactitud.** Ambos modelos mantienen *recall* elevado (≈ 0.83) a costa de una ligera caída de precisión (0.76 – 0.77), coherente con haber entrenado en un subconjunto equilibrado mientras el *test* está algo desbalanceado.
4. **Eficiencia computacional.** Entrenar 10k frente a 20k reduce las GPU-horas casi a la mitad con un coste en F1 de sólo 4–5 pp: un compromiso interesante para proyectos con recursos limitados pero algo a evitar para aquellos en los que prime la calidad de las clasificaciones.
5. **Conclusión práctica.** Un modelo BERT “clásico” con la mitad de los datos *supera* a todos los baselines clásicos (XGBoost, DistilBERT) y se queda a ≈ 5 pp del mejor baseline DeBERTa. No obstante, cerrar la brecha de 8–9pp que falta hasta el estado del arte requiere de más datos o *continued pre-training* (como presentan esos modelos en el top), arquitecturas grandes (DeBERTa-v3-large) o del uso de técnicas de *ensemble* y aprendizaje multi-tarea.

4.4.2. Caso RedditBIAS. Sesgo vs. Sexismo

Según el European Institute for Gender Equality, podemos definir el sesgo de género y el sexismo como:

- **Sesgo de género** ⁴: «Acciones o pensamientos prejuiciosos basados en la percepción en función del sexo de que las mujeres no son iguales que los hombres en derechos y en dignidad.»
- **Sexismo** ⁵: «Acciones o actitudes que discriminan contra personas únicamente por cuestión de su sexo y/o género.»

Esto hace que no todos los «biased» sean sexismo y lo mismo ocurre al contrario. Una vez dejado esto claro, en la tabla 4.22 veremos algunos ejemplos de frases en *RedditBIAS* que tienen discordancia. Para dicho análisis hemos utilizado los tres modelos que mejor se adaptaron al corpus de RedditBIAS y no clasificaron todo de una misma clase, estos modelos son:

- bert-base-uncased
- ModernBERT-base
- Mistral-7B-Instruct-v0.3

En la tabla observaremos la anotación del propio dataset de *RedditBIAS*, así como las tres anotaciones de cada modelo en cada una de las variaciones del clasificador (binario, 3 etiquetas y 4 etiquetas).

⁴https://eige.europa.eu/publications-resources/thesaurus/terms/1320?language_content_entity=es

⁵https://eige.europa.eu/publications-resources/thesaurus/terms/1325?language_content_entity=es

Comment			True label
<i>i do enjoy cooking. my wife is a vegetarian so maybe ill try to figure out a dish for her.</i>			unbiased
Model	Binary	3 labels	4 labels
bert-base-uncased	not sexist	not sexist	low conf.
ModernBERT-base	not sexist	not sexist	not sexist
Mistral-7B-Instruct-v0.3	sexist	not sexist	not sexist
<i>i would tip heavy for that kind of attention to detail and pure art work. and my mom is a hoe. fo sho.</i>			unbiased
Model	Binary	3 labels	4 labels
bert-base-uncased	sexist	sexist	not sexist
ModernBERT-base	sexist	sexist	not sexist
Mistral-7B-Instruct-v0.3	sexist	sexist	sexist
<i>my friends mom is the best cook ive ever seen and no shes not a milf you sick people</i>			biased
Model	Binary	3 labels	4 labels
bert-base-uncased	sexist	unsure	low conf.
ModernBERT-base	sexist	unsure	not sexist
Mistral-7B-Instruct-v0.3	not sexist	not sexist	not sexist
<i>my mom is a housekeeper and now im thankful practically no one in spain uses reddit</i>			biased
Model	Binary	3 labels	4 labels
bert-base-uncased	not sexist	not sexist	not sexist
ModernBERT-base	not sexist	not sexist	not sexist
Mistral-7B-Instruct-v0.3	sexist	not sexist	not sexist

Tabla 4.22: Ejemplos de frases con sus predicciones (RedditBIAS). En verde las que se mapean como unbiased y en rojo las biased.

En la tabla 4.22 mostramos 4 comentarios que ejemplifican los distintos casos que podemos encontrarnos:

1. *i do enjoy cooking. my wife is a vegetarian so maybe ill try to figure out a dish for her.* En el dataset está etiquetada como **unbiased** y los modelos concuerdan con eso, ya que es una frase de carácter neutro en el que no se aprecian ni sesgo de género ni sexismo.
2. *i would tip heavy for that kind of attention to detail and pure art work. and my mom is a hoe. fo sho.* En el dataset está etiquetada como **unbiased**, pero todos los modelos concuerdan que sí que hay sexismo, muy probablemente debido a «*my mom is a hoe*».
3. *my friends mom is the best cook ive ever seen and no shes not a milf you sick people.*

En el dataset está etiquetada como *biased* y los modelos son dispares a la hora de etiquetarla. Mientras que *Mistral* no encuentra sexismo alguno en ninguna de los etiquetados, los dos *BERT* sí que reconocen un sexismo. Esto puede ser por la palabra «MILF», acrónimo de «*Mother I'd Like to Fuck*», que los modelos reconocen como sexismo, en diferente grado, excepto en el *ModernBERT* de 4 etiquetas.

4. *my mom is a housekeeper and now im thankful practically no one in spain uses reddit.* En el dataset está etiquetada como *biased*, pero todos los modelos concuerdan en que no hay sexismo, cosa objetivamente cierta de acuerdo a la definición del mismo. Lo que sí podría haber es un sesgo al relacionar «mom – housekeeper».

4.4.3. Análisis de casos en EDOS

A continuación vamos a analizar 6 frases del dataset de EDOS (*split de test*) clasificadas usando los modelos de *bert-base-uncased*, *ModernBERT-base* y *Mistral-7B-Instruct-v0.3* ya que son los modelos que mejor han funcionado según los resultados vistos anteriormente.

Se ha incluido el número de anotadores (0-3) que marcaron el comentario como sexista. «3 sexist» significa consenso pleno en que el comentario es sexista; «0 sexist» indica que ningún anotador la consideró sexista.

En la tabla 4.23 mostramos 6 comentarios que ejemplifican algunos de los casos que podemos encontrarnos:

1. *I contacted her but never heard from her so I chalked it up to nothing.* Todos los sistemas coinciden con los anotadores, la frase solo describe una interacción fallida, sin insultos ni estereotipos.
2. *I always wanted to see one of those so I could run up, pull out my cock and fuck her face.* El lenguaje sexual explícito y violento acerca la frase al sexismo, pero la falta de insulto directo provoca incertidumbre en los modelos *BERT*, mientras que *Mistral* opta por alta confianza.
3. *If a female is having sex and relationships they do not have social anxiety.* Con 2 y 3 etiquetas todos los LLMs coinciden en que es sexista, al introducir una cuarta ya dudan más del grado, posiblemente porque da una pseudo explicación y no es un insulto directo.
4. *You incels bitch about how terrible and miserable and psychologically-damaging your lives are because you don't have sex, but as soon as a woman has surgery to get *out* of that situation, she's selfish?* El insulto directo de “incels bitch” y la doble moral hace que los modelos lo tomen como completamente sexista.
5. *That hug could turn into a false sexual assault or rape conviction down the road....this is damn good advice for men...never touch any girl or woman....let them wither on the vine from lack of attention.* Acusa a las mujeres de denunciar falsamente, lo cual es un clásico discurso sexista, pero lo hace utilizando condicionales “could turn” y de forma ambigua que los modelos *BERT* no consiguen afinar del todo mientras que *Mistral* sí.

6. *It's fucked up how women aren't allowed to even be neutral. Always have to put on a fucking show to entertain men and keep them from attacking you.* En este caso vemos un caso de denuncia frente al sexismo, con sarcasmo e insultos, que hace que todos los modelos disparen un falso positivo y se decanten por marcarlo como completamente sexista.

Podemos observar algunas tendencias como:

- **Alta concordancia cuando el consenso humano es unánime.** Todos los casos “3 sexist” reciben la etiqueta sexist; los “0 sexist” solo fallan cuando la frase critica el sexismo usando lenguaje soez.
- **Modelos BERT tienen resultados casi idénticos.** Sólo difieren en la clasificación con 4 etiquetas, lo que sugiere que la arquitectura base domina el comportamiento.
- **Errores sistemáticos: ironía o lenguaje vulgar.** Todos los sistemas se confunden en presencia de denuncias de sexismo, ironía o lenguaje malsonante, demostrando que el detector confunde “hablar de sexismo” con “ser sexista”.

Comment			Annotators
<i>I contacted her but never heard from her so I chalked it up to nothing</i>			0 sexist (not sexist)
Model	Binary	3 labels	4 labels
bert-base-uncased	not sexist	not sexist	not sexist
ModernBERT-base	not sexist	not sexist	not sexist
Mistral-7B-Instruct-v0.3	not sexist	not sexist	not sexist
<i>I always wanted to see one of those so I could run up, pull out my cock and fuck her face.</i>			2 sexist (unsure / high conf.)
Model	Binary	3 labels	4 labels
bert-base-uncased	sexist	unsure	high conf.
ModernBERT-base	sexist	unsure	high conf.
Mistral-7B-Instruct-v0.3	sexist	sexist	sexist
<i>If a female is having sex and relationships they do not have social anxiety.</i>			3 sexist (sexist)
Model	Binary	3 labels	4 labels
bert-base-uncased	sexist	sexist	high conf.
ModernBERT-base	sexist	sexist	low conf.
Mistral-7B-Instruct-v0.3	sexist	sexist	low conf.
<i>You incels bitch about how terrible and miserable and psychologically-damaging your lives are because you don't have sex, but as soon as a woman has surgery to get *out* of that situation, she's selfish?</i>			2 sexist (unsure / high conf.)
Model	Binary	3 labels	4 labels
bert-base-uncased	sexist	sexist	sexist
ModernBERT-base	sexist	sexist	high conf.
Mistral-7B-Instruct-v0.3	sexist	sexist	high conf.
<i>That hug could turn into a false sexual assault or rape conviction down the road....this is damn good advice for men...never touch any girl or woman....let them wither on the vine from lack of attention.</i>			3 sexist (sexist)
Model	Binary	3 labels	4 labels
bert-base-uncased	sexist	unsure	low conf.
ModernBERT-base	sexist	unsure	high conf.
Mistral-7B-Instruct-v0.3	sexist	sexist	sexist
<i>It's fucked up how women aren't allowed to even be neutral. Always have to put on a fucking show to entertain men and keep them from attacking you.</i>			0 sexist (not sexist)
Model	Binary	3 labels	4 labels
bert-base-uncased	sexist	sexist	sexist
ModernBERT-base	sexist	sexist	sexist
Mistral-7B-Instruct-v0.3	sexist	sexist	sexist

Tabla 4.23: Ejemplos de frases con sus predicciones (EDOS).

4.5. Discusión

En este capítulo sintetizamos los principales hallazgos empíricos y reflexionamos sobre las limitaciones que condicionan los resultados. Además, señalamos líneas de trabajo que podrían mejorar la detección automática de sexismo.

Para contextualizar los hallazgos, resumimos primero el rendimiento de los modelos según la granularidad del esquema de etiquetas. Partimos de la clasificación binaria (donde el objetivo es separar de forma gruesa contenido sexista de no sexista) y, a continuación, analizamos cómo evoluciona la calidad cuando se exige distinguir tres y cuatro categorías. Este recorrido incremental nos permitirá valorar el compromiso entre detalle analítico y robustez práctica antes de discutir la transferencia de dominio y el balance coste-beneficio.

Clasificación binaria Con $F1 \approx 0.84$ en EDOS-10k, ModernBERT-base se consolida como filtro de primer nivel: recall alto (≥ 0.85) y precisión suficiente (~ 0.83). Los LLM *few-shot* no cierran la brecha (máx. $F1 \approx 0.56$ en EDOS-5k). La transferencia a RedditBIAS se degrada ($F1 \approx 0.45$) por la naturaleza más sutil de los estereotipos, mientras que en frases sintéticas BERT y Mistral alcanzan $F1 \geq 0.95$, evidenciando su fortaleza ante ejemplos controlados.

Tres etiquetas Unificar las dos subclases de sexismo eleva el $F1$ macro a ~ 0.68 . ModernBERT vuelve a liderar por una décima sobre BERT-base y muestra equilibrio entre precisión y recall en `not sexist/sexist`. La categoría `unsure` concentra la mayor parte de los errores, por lo que se propone canalizarla hacia revisión humana. La generalización de los BERT a RedditBIAS sigue siendo limitada ($F1 \approx 0.41$), confirmando la necesidad de adaptación de dominio.

Cuatro etiquetas La granularidad introduce una penalización de ≈ 30 pp ($F1 \approx 0.52$). BERT-base supera a ModernBERT y a todos los LLM, pero ninguno alcanza umbrales de despliegue sin supervisión. Los errores se reparten entre (i) confundir `sexist (low)` con `not sexist` y (ii) infradetectar `sexist (high)`. Se recomienda un pipeline jerárquico (binario $\rightarrow$ multiclase) o técnicas de *label smoothing* para mejorar la discriminación entre niveles de certeza.

Transferencia de dominio En RedditBIAS y Synthetic Phrases los resultados confirman la regla: cuanto mayor es la divergencia del dominio de entrenamiento, mayor la caída de rendimiento, especialmente en etiquetados finos. Incorporar datos externos o emplear *domain-adaptation* es imprescindible si se desea mantener $F1 \geq 0.6$ fuera del dominio de entrenamiento.

Coste-beneficio Pasar de 2 a 3 etiquetas reduce el $F1$ macro de 0.84 a 0.68 (-16 pp) a cambio de introducir la clase `unsure`, útil para filtrar casos dudosos. Aumentar a 4 etiquetas vuelve a restar ~ 16 pp ($0.68 \rightarrow 0.52$) y sólo separa el nivel de consenso (`low` vs. `high`), de escaso valor operativo. Por tanto, el esquema triclase ofrece la mejor relación detalle-rendimiento; la cuatriclase sólo compensa si el grado de acuerdo entre anotadores resulta crítico para la aplicación.

4.5.1. Lecciones extraídas de *EDOS*

- **Cobertura del sexismo explícito.** Los tres modelos etiquetan *sexist* todos los ejemplos con consenso humano “3 sexist”, confirmando que en estos casos capturan bien insultos directos, cosificación y argumentos de inferioridad.
- **Falsos positivos en discurso antisexista.** Frases que denuncian la discriminación usando lenguaje soez producen errores sistemáticos (Tabla 4.23), lo que evidencia la ausencia de un módulo que distinga *objetivo* y *emisor*.
- **Utilidad de *unsure/low-conf./high-conf.*** Los textos que expresan algún tipo de desacuerdo o ambigüedad y se clasifican con las etiquetas intermedias sirven como filtro para priorizar revisión humana.

4.5.2. Limitaciones del estudio

Dominio lingüístico anglófono. Todos los corpus empleados (*EDOS*, *RedditBIAS* y *Synthetic Phrases*) están redactados en inglés, por lo que los modelos sólo se exponen a fenómenos culturales y pragmáticos propios de la comunidad anglo-parlante. Esta monolingüalidad restringe la validez externa: no sabemos si los clasificadores transferirán correctamente a otros idiomas, donde el sexismo puede materializarse con construcciones sintácticas y referencias culturales distintas.

Subjetividad y desacuerdo anotador. El sexismo es un fenómeno subjetivo; aun con directrices claras, los anotadores discrepan sobre el tono, la ironía o la intención del emisor. Las etiquetas *unsure/low-conf./high-conf.* han revelado esa “zona gris”, pero el desacuerdo persiste: en *EDOS* existen ejemplos con distribución 2 sexist / 1 not que los modelos tienden a rechazar porque no detectan hostilidad explícita.

Cobertura temática distinta: bias *versus* sexismo. *RedditBIAS* engloba cualquier estereotipo de género, con o sin agresión lingüística, mientras que nuestro objetivo es el *sexismo* (subconjunto que exige desprecio o degradación). La comparación directa genera falsos *positivos* (comentarios “biased” pero no sexistas) y falsos *negativos* (mensajes anti-sexistas que usan insultos para denunciar el problema). La tabla 4.22 ilustra varios casos.

Capacidad y ajuste de los modelos. Los modelos de la familia BERT usados capturan bien el sexismo explícito cuando el ejemplo es similar a los vistos durante el fine-tuning, pero fallan ante formulaciones irónicas o cuando la víctima no es obvia. Mistral-7B, pese a su mayor tamaño y entrenamiento instructivo, muestra mayor variabilidad: detecta matices violentos que BERT ignora, pero también se deja engañar por el contexto (Ej. 6 de *EDOS* - tabla 4.23). La escasez de ejemplos en idiomas o registros específicos limita el aprendizaje de patrones sutiles (ej. humor negro o alusiones culturales).

4.6. Conclusiones y trabajos futuros

Los experimentos realizados en este trabajo confirman que los modelos basados en BERT, y en menor medida los LLM ajustados mediante *instruction-tuning*, resultan eficaces para detectar ejemplos claros de sexismo. No obstante, cuando el discurso se vuelve

sutil (por ejemplo, adopta un tono irónico, se refugia en estereotipos o simplemente denuncia el propio machismo) los sistemas siguen cometiendo errores recurrentes. En particular, tienden a confundir *crítica al sesgo* con el sesgo mismo, y muestran dificultades para discriminar entre niveles de agresividad cuando se introducen etiquetas de confianza más finas.

El análisis comparado revela además tres tendencias clave:

- **Robustez frente a granularidad.** Los clasificadores mantienen un rendimiento alto en el esquema binario, pero la precisión se deteriora a medida que se añaden categorías intermedias. Las clases intermedias se comportan como una válvula de escape para la ambigüedad, lo que sugiere un uso pragmático: derivar esos casos a revisión humana.
- **Dependencia del dominio.** Al transferir los modelos a foros con un estilo retórico distinto (p.ej. *RedditBIAS*) se observa una caída apreciable, sobre todo cuando el sesgo se manifiesta sin lenguaje explícitamente ofensivo.
- **Impacto del tamaño de datos.** Trabajar con la mitad del corpus anotado conserva la mayor parte de la señal, pero deja una brecha frente al estado del arte obtenida con arquitecturas de mayor capacidad o preentrenamientos especializados.

Estas observaciones sitúan la investigación en un punto intermedio: disponemos de un filtro automático fiable para detección grosera, pero aún lejos de una herramienta que distinga con matices la intencionalidad, el contexto cultural y la sutileza pragmática del discurso.

Líneas de trabajo abiertas

1. **Modelar el *target* del discurso.** Incorporar una etapa que identifique quién es el destinatario del insulto (mujer, colectivo LGTBI, autorreferencia, etc.) reduciría los falsos positivos cuando se critica el sexismo.
2. **Fine-tuning con ejemplos críticos.** Añadir comentarios antisexistas, ironía y contra-argumentos al conjunto de entrenamiento aumentará la robustez ante lenguaje ambiguo.
3. **Enriquecer la señal de confianza.** Los niveles *low/high conf.* han resultado informativos; se puede extender a una probabilidad calibrada que permita umbrales flexibles según la aplicación (moderación automática versus análisis estadístico).
4. **Evaluación multilingüe.** Replicar la metodología en corpora español, francés o portugués (incluyendo variaciones dialectales) para comprobar la portabilidad del enfoque y, de paso, generar recursos escasos fuera del ámbito anglófono.
5. **Métricas equitativas.** En *RedditBIAS* basta con predecir siempre la clase mayoritaria para lograr un F1 aparentemente competitivo. Necesitamos métricas que penalicen ese “todo 1/0” y que luego promedien sin ponderar por tamaño de clase. Así obtendríamos una evaluación verdaderamente equitativa cuando el dataset está desbalanceado o combina fenómenos distintos.

6. **Aprendizaje continuo y detección de deriva.** Integrar un mecanismo que actualice el modelo con ejemplos revisados por moderadores y que alerte de desplazamientos temáticos (nuevas formas de acoso, jerga emergente) mantendrá la eficacia a lo largo del tiempo.

Abordar estos frentes permitirá avanzar hacia clasificadores de sexismo más robustos, transparentes y aplicables en entornos reales, donde el lenguaje evoluciona y las fronteras entre crítica, ironía y agresión se difuminan. Con ello se contribuirá no solo a mejorar la moderación automática, sino también al estudio empírico de los sesgos de género en la comunicación digital.

Capítulo 5

Aplicaciones en sistemas reales

En este capítulo describimos la propuesta completa (desde la arquitectura de despliegue hasta la experiencia de usuario) para demostrar que los modelos y flujos de trabajo desarrollados pueden integrarse sin fricciones en un producto software real.

5.1. Arquitectura general

- **Backend.** Se ha implantado un *microservicio* en **FastAPI** que expone un conjunto de endpoints REST. Esta elección aporta:
 1. Alto rendimiento frente a servidores WSGI tradicionales gracias a *uvicorn*.
 2. Validación automática de datos y documentación autogenerada vía `/docs`.
 3. Despliegue sencillo en contenedores OCI (**docker**/**podman**) o en empaquetados *serverless* (AWS Lambda, Google Cloud Run, etc.).
- **Frontend.** Para la interfaz gráfica se ha utilizado **React 18**, una librería de JavaScript que permite reutilizar partes del código como «componentes», permitiendo mayor flexibilidad y agilidad a la hora de desarrollar la web.

Tras compilar el proyecto, el propio FastAPI sirve los archivos estáticos del frontend (`index.html`, `*.js`, `*.css`) a través de un único puerto. De esta forma reducimos costes operativos al evitar un segundo servidor (Nginx, Apache o similar).

5.2. Caso de uso: aplicación de análisis de sexismo

El principal caso de uso implementado es un *analizador de sexismo*. El servicio permite al usuario analizar textos aislados, URLs o dominios web completos. El pipeline ya se detalló en la sección 3.1, pero aquí se describe cómo se materializa en la interfaz.

5.2.1. Inicio de sesión



Figura 5.1: Pantalla de inicio de sesión

La figura 5.1 presenta un *login* minimalista: formulario a la izquierda y un panel estático, en gris corporativo con el logo de la Universidad de Granada, que muestra el título del proyecto. El formulario valida usuario y contraseña en el servidor y, tras autenticación, almacena el token de acceso en `sessionStorage` (no en cookies).

El *login* sirve como barrera para el resto de páginas, bloqueando y redirigiendo al inicio de sesión si no está presente el token de acceso o este ha caducado.

5.2.2. Página de inicio




Figura 5.2: Panel principal *post-login*.

Tal y como se aprecia en la figura 5.2, optamos por una cuadrícula de cuatro tarjetas

en vez del clásico menú lateral. A su vez, todas las páginas cuentan con un encabezado con:

- El logo de la universidad (que redirige a esta *Home Page*).
- El menú desplegable con las distintas opciones de la aplicación (visibles según el rol del usuario como se explicará más adelante).
- El icono de usuario para el menú desplegable con el que se podrá cerrar sesión y acceder al perfil del usuario.

5.2.3. Detector de sexismo

Panel de selección de modo.




Figura 5.3: Selector de modo de detección de sexismo.

En la figura 5.3 el usuario decide si analizar *Textos*, *URLs* individuales o *Dominios* completos.

Detector de sexismo en texto




Figura 5.4: Formulario para análisis de texto.

En el formulario (figura 5.4) el usuario pega o redacta un texto de longitud arbitraria. Tras pulsar “*Analizar Texto*” se lanza una petición al backend¹ cuyo resultado se renderiza de la siguiente manera:

¹Se hace uso del modelo **ModernBERT-base** con la clasificación para dos etiquetas.




Figura 5.5: Resultados del análisis de texto.

Lo primero que observamos es un gráfico radial con el % de frases sexistas y el listado frase a frase. Además del porcentaje global de contenido catalogado como sexista, cada frase se etiqueta como **sexist** o **not sexist** junto a la probabilidad, facilitando la revisión manual.

Análisis de URL

The screenshot displays the 'Detector de Sexismo en URL' interface. At the top, there is a header with the University of Granada logo and navigation links: 'Detector Sexismo', 'Analíticas', and 'Panel Administración'. The main section is titled 'Detector de Sexismo en URL' and includes a text input area with a placeholder 'Introduce la URL absoluta'. Below the input, there is a button labeled 'Analizar URL'. There is also an optional field for 'Etiqueta HTML (opcional)' with a placeholder 'article, p, div...'. A button labeled 'Analizar URL' is also present below this field.

Figura 5.6: Formulario de análisis de URL.

La interfaz para URLs (figura 5.6) acepta una ruta absoluta y (opcionalmente) la etiqueta HTML a extraer/filtrar del contenido. El campo opcional “Etiqueta HTML” permite restringir el *scrapeo*, p.ej. a **article** como es el caso de las páginas del dominio de la Universidad de Granada.




Figura 5.7: Resultados del análisis de una URL.

El resultado (figura 5.7), al igual que el detector de texto, incluye:

- Análisis global de sexismo en la URL.
- Análisis por frase. Útil para mostrar al editor dónde debería actualizar el artículo.

Análisis de dominio



Figura 5.8: Formulario del analizador de dominio.

Esta vista permite introducir un dominio absoluto (p.ej., <https://www.ugr.es/>). Al ejecutar el análisis, el backend respeta `robots.txt` y localiza el `sitemap.xml` (o todos

los que tenga en caso de haber más de uno). Extrae las URLs indexables (evitando *scra-peo* indiscriminado y realizándolo de la forma menos dañina posible para los servidores del dominio) y, además, encola las páginas y ejecuta inferencia en paralelo, almacenando resultados por URL.




Figura 5.9: Resultado del análisis de un dominio.

La respuesta se presenta como en figura 5.9: tarjeta de estado del dominio y sumario del proceso (sitemaps utilizados, número de URLs encontradas por sitemap y su estado). Desde aquí puede abrirse la página de resultados detallados (sección de Analíticas).

Prueba de concepto en la UGR. Para la validación práctica se analizó el portal principal de la Universidad de Granada. Dado que la guía de estilos del CEPRUD establece que los contenidos en inglés deben ubicarse bajo el directorio `/en/`, filtramos las URLs que cumplieran dicho patrón para poder así analizarlas con nuestro detector de sexismo (recordemos que está entrenado con textos en inglés).

Se ha hecho uso solamente del sitio web principal de la UGR ya que, si bien es cierto que la web principal ofrece un número suficiente de páginas traducidas para una evaluación representativa, los subdominios de facultades y centros presentan una carencia notable de traducciones.

Los resultados obtenidos de analizar el dominio **www.ugr.es** son los siguientes:

- **Se han analizado 590 URLs** (todas colgando del directorio */en/*).
- A partir de esas URLs, se han analizado **12643 frases**, de las cuales **solo 22 han dado positivo en la detección de sexismo**. Algunas de estas frases son:
 - «Women take longer to seek help, despite more frequently recognizing that it could be a cardiovascular event Rapid treatment in the event of a heart attack is crucial to saving lives and reducing complications.»
 - «Historically, the media has contributed to this marginalisation of women; for example, media coverage of female athletes is often minimal or even non-existent.»

Como era de esperar de una web institucional, el porcentaje de sexismo detectado ($\approx 0.002\%$) es muy bajo, y los ejemplos revisados que estaban marcados como sexistas han sido falsos positivos (especialmente cuando se habla sobre discriminación aunque sea posicionándose a favor de la mujer, como ya vimos en subsección 4.5.1). Teniendo en cuenta la cantidad de frases analizadas, que “solo” haya habido ese porcentaje tan bajo también es un buen resultado, pues el modelo no tacha de sexista cualquier cosa.

5.2.4. Analíticas

Este módulo consolida los resultados persistidos por el analizador y ofrece tres vistas: (i) analíticas globales, (ii) listado de dominios y (iii) listado de URLs de un dominio.

Analíticas globales





Figura 5.10: Dashboard global de las analíticas.

La figura 5.10 muestra:

- **Indicadores** de actividad: URLs analizadas, frases totales, frases con sexismo y % global estimado.

- **Top 5 frases** clasificadas como sexistas (con la probabilidad asignada) para revisión editorial rápida.
- **Distribución de severidad:** histograma de probabilidades que ayuda a ajustar umbrales operativos.

Analíticas por dominio




Dominio	URL Absoluta	
www.ugr.es	https://www.ugr.es	⋮
quillette.com	https://quillette.com	⋮
everydaysexism.com	https://everydaysexism.com/	⋮

Figura 5.11: Listado de dominios con URLs analizadas.

Esta vista (figura 5.11) recoge todos los dominios que contienen URLs analizadas, su URL absoluta y un menú contextual (tres puntos) con acciones: *ver URLs* y *eliminar*. La barra de búsqueda filtra por dominio/URL.

Analíticas de URLs de un dominio



URL Relativa	% Sexismo	Clasificación
/en/about	0.00%	No sexista
/en/about/authority-electronic-site	0.00%	No sexista
/en/about/facts-figures	0.00%	No sexista
/en/about/history	0.48%	No sexista
/en/about/history/chronology	0.16%	No sexista
/en/about/history/university-city	0.01%	No sexista
/en/about/history/university-today	0.02%	No sexista
/en/about/international-strategy	0.00%	No sexista
/en/about/news/10th-international-staff-training-week-15-19-jan-2018	0.00%	No sexista
/en/about/news/12th-international-staff-training-week-takes-ugr	0.11%	No sexista

Figura 5.12: Listado paginado de URLs de un dominio.

Al entrar en un dominio concreto se muestra el listado de URLs (figura 5.12) ordenadas por defecto por orden alfabético. Incluye:

- **Filtros** por estado (sexistas/no sexistas) y por presencia de frases marcadas.

- **Paginación** para grandes volúmenes.
- Acceso al **detalle de una URL**.

Analíticas de URL específica




Figura 5.13: Detalle del análisis de una URL concreta.

En la figura 5.13 podemos observar el análisis en detalle realizado sobre la URL, ya descrito en subsección 5.2.3.

5.3. Persistencia de resultados

Para el almacenamiento se emplea una base de datos **SQLite 3** embebida. Sus ventajas en esta fase son:

- Cero configuración y ausencia de proceso servidor independiente.
- Rendimiento suficiente para decenas de miles de análisis puntuales.

En un futuro despliegue de producción se recomienda migrar a PostgreSQL o MySQL para gestionar concurrencia, copias de seguridad y *sharding* si fuese necesario.

5.4. Gestión de usuarios y permisos

El sistema implementa **autenticación JWT** y tres roles:

- **admin**: Acceso total a la aplicación, incluida la gestión de usuarios y ajustes globales.
- **sexism_detection**: Permisos para lanzar y visualizar análisis, sin capacidad de administración.
- **analytics**: Rol visualizador de la sección de analíticas.

El rol del usuario se recoge haciendo uso del token de acceso y permitirá mostrarle total o parcialmente el contenido de la aplicación.




Figura 5.14: Panel de administración: Gestión de roles.

La figura 5.14 muestra la página para gestionar los roles de la aplicación, no obstante, al tener propiedades adquiridas de forma programática (p. ej. que sólo pueda accederse a determinadas secciones), esta página sirve como apoyo a la ampliación de la aplicación con el objetivo de no manejar los roles directamente desde base de datos.

Desde el panel de administración es posible crear distintos usuarios y asignarles un rol diferente a cada uno de ellos.




Figura 5.15: Panel de administración: Gestión de usuarios.

Cada usuario de la aplicación puede acceder a su página de perfil, desde donde podrá visualizar sus datos y modificar su contraseña.



Figura 5.16: Perfil de usuario.

5.5. Flujo de navegación

La siguiente tabla ilustra el recorrido típico en tres perfiles de usuario.

Tabla 5.1: Flujo resumido de navegación según rol.

Rol	Acción inicial	Pantallas recorridas
user	Analizar texto	<i>Login → Panel → Texto → Resultados</i>
analysis	Auditar dominio	<i>Login → Panel → Dominios → URLs → Resultados</i>
admin	Crear cuenta	<i>Login → Admin Panel → Users → Panel</i>

5.6. Lecciones aprendidas y trabajo futuro

- La arquitectura basada en FastAPI + React se adapta bien a MVPs (Producto Mínimo Viable) con presupuesto reducido y baja curva de aprendizaje.
- SQLite ha resultado suficiente para una prueba piloto, pero la falta de **row-level locking** impone un límite claro para cargas de trabajo concurrentes.
- Añadir **i18n** tanto en frontend como en backend facilitaría su adopción en organizaciones internacionales.
- Un módulo para **entrenamiento continuo** permitiría refinar el clasificador con retroalimentación de usuarios expertos.

Con esta implementación demostramos que el trabajo no se queda en un prototipo académico, sino que puede integrarse de forma eficiente en un entorno de producción real, aportando valor inmediato a los responsables de contenido y comunicación digital.

Capítulo 6

Conclusiones y trabajos futuros

6.1. Conclusiones principales

Este Trabajo Fin de Máster demuestra que un enfoque basado en BERT sigue siendo competitivo para la detección automática de sexismo, siempre que se combine con (i) un preprocesado cuidadoso y (ii) una búsqueda de hiperparámetros selectiva:

- Con sólo 10k ejemplos equilibrados de EDOS, **ModernBERT-base** alcanza $F1 = 0.84$ y $recall = 0.85$, superando ligeramente a *bert-base-uncased* en el mismo escenario.
- Los LLMs generativos con *few-shot prompting* mejoran sobre modelos de tamaño similar pero todavía quedan ≥ 40 puntos por detrás en F1 si no se afinan los pesos.
- La reducción del conjunto de entrenamiento ha supuesto un ahorro de hasta un 50 % en GPU-horas con una pérdida de rendimiento de sólo 4pp del mejor baseline de SemEval-2023 (*DeBERTa-v3-base* con $F1 = 0.8235$ frente a nuestro *bert-base-uncased* con $F1 = 0.79$).
- La API FastAPI + React valida que el clasificador puede desplegarse con rendimiento suficiente para uso en tiempo real, incluso en hardware modesto.

Aun así, el análisis de errores revela varias limitaciones ya expuestas en las **Líneas de mejora** de la sección 4.6: confusión entre crítica al sexismo y sexismo real, falta de robustez ante ironía, ausencia de evaluación multilingüe y dependencia excesiva de la distribución de clases.

Los resultados obtenidos confirman que un modelo bien ajustado y un flujo de trabajo ligero pueden servir de primera defensa contra el sexismo en línea. Los pasos propuestos abren el camino hacia sistemas más precisos, rápidos y fáciles de integrar en aplicaciones reales, asegurando un impacto tangible en la creación de entornos digitales más seguros e inclusivos.

6.2. Trabajos futuros

Sobre la base de los puntos anteriores, proponemos las siguientes líneas de continuidad:

6.2.1. Mejora del modelo y de la métrica

- **Objetivo explícito del discurso.** Añadir un subtarea que identifique a quién va dirigido el mensaje (mujer, colectivo LGTBI, autorreferencia, etc.) para reducir los falsos positivos señalados en sección 4.6.
- **Fine-tuning con ejemplos críticos.** Incluir frases antidiscursivas, ironía y contra-argumentos (tal como se sugiere en la línea 2 de la sección 4.6) reforzaría la robustez semántica.
- **Métricas equitativas.** Adoptar una métrica que penalice el sesgo hacia la clase mayoritaria, por ejemplo *macro AUROC* o el *false-alarm penalty* propuesto recientemente, para evitar F1 engañosos en datasets muy desbalanceados.

6.2.2. Arquitectura y eficiencia

- **Quantized LoRA (QLoRA).** Explorar QLoRA para reducir el tamaño y el consumo de VRAM de los modelos de medio-tamaño, de modo que puedan ejecutarse en GPU de 8 GB o incluso en CPU.
- **Modelos ligeros de última generación.** Evaluar variantes como *Phi-3-mini* o *MobiLlama* para ofrecer detección instantánea en dispositivos de bajo coste.

6.2.3. Aplicaciones prácticas

- **Extensión de navegador.** Desarrollar un *plugin* que marque automáticamente sexismo, discurso de odio, noticias falsas o discriminación al vuelo mientras se navega, reutilizando la API existente.
- **Filtro parental en redes y chats.** Adaptar el modelo para que opere en segundo plano (por ejemplo, como servicio en Android) y avise a los tutores cuando un menor reciba mensajes potencialmente dañinos.
- **Incluir *Speech-to-text*.** Añadiendo modelos que sean capaces de transcribir el audio nos permite analizar no solo contenido en formato de texto si no también audios o vídeos.
- **Reconocimiento Óptico de Caracteres (OCR).** Al igual que con los audios y vídeos del punto anterior, tener una herramienta OCR que permita extraer el texto de las imágenes nos permitirá analizar el mismo para detectar posibles mensajes sexistas, algo muy útil en redes sociales (alta presencia de “memes”, algunos de los cuales pueden contener sexismo).

6.2.4. Ampliación de datos y cobertura

- **Dataset 2025 y multilingüe.** Incluir el nuevo corpus BeyondGender-2025 y otros recursos en español, francés o chino para entrenar un clasificador verdaderamente multilingüe, tal como se sugiere en la línea 4 de sección 4.6.
- **Más ejemplos *few-shot*.** Curar un banco de demostraciones con anotación rica (tono, objetivo, confianza) que mejore las LLMs en *zero/few-shot prompting*.

Bibliografía

- [1] Peter Glick y Susan T. Fiske. «The Ambivalent Sexism Inventory: Differentiating hostile and benevolent sexism.» En: *Journal of Personality and Social Psychology* 70.3 (mar. de 1996), págs. 491-512. DOI: 10.1037/0022-3514.70.3.491. URL: https://www.researchgate.net/publication/232548173_The_Ambivalent_Sexism_Inventory_Differentiating_Hostile_and_Benevolent_Sexism.
- [2] Hannah Rose Kirk et al. «SemEval-2023 Task 10: Explainable Detection of Online Sexism». En: *Proceedings of the 17th International Workshop on Semantic Evaluation (SemEval-2023)*. Association for Computational Linguistics, 2023. DOI: 10.48550/arXiv.2303.04222. URL: <http://arxiv.org/abs/2303.04222>.
- [3] Soumya Barikeri et al. «RedditBias: A Real-World Resource for Bias Evaluation and Debiasing of Conversational Language Models». En: *CoRR* abs/2106.03521 (2021). arXiv: 2106.03521. URL: <https://arxiv.org/abs/2106.03521>.
- [4] Maeve Duggan. *Online Harassment 2017*. en-US. Jul. de 2017. URL: <https://www.pewresearch.org/internet/2017/07/11/online-harassment-2017>.
- [5] Tomas Mikolov et al. *Efficient estimation of word representations in vector space*. Ene. de 2013. URL: <https://arxiv.org/abs/1301.3781>.
- [6] Xinying Song et al. *Fast WordPiece Tokenization*. 2021. arXiv: 2012.15524 [cs.CL]. URL: <https://arxiv.org/abs/2012.15524>.
- [7] Ashish Vaswani et al. *Attention is all you need*. Jun. de 2017. DOI: 10.48550/arXiv.1706.03762.
- [8] *What are Large Language Models (LLMs)?* IBM. 2023. URL: <https://www.ibm.com/think/topics/large-language-models>.
- [9] Zeerak Waseem. «Are You a Racist or Am I Seeing Things? Annotator Influence on Hate Speech Detection on Twitter». En: *Proceedings of the First Workshop on NLP and Computational Social Science*. Ed. por David Bamman et al. Austin, Texas: Association for Computational Linguistics, nov. de 2016, págs. 138-142. DOI: 10.18653/v1/W16-5618. URL: <https://aclanthology.org/W16-5618/>.
- [10] Elisabetta Fersini, Debora Nozza y Paolo Rosso. *Overview of the Evalita 2018 Task on Automatic Misogyny Identification (AMI)*. Ene. de 2018. DOI: 10.4000/books.aaccademia.4497. URL: https://www.researchgate.net/publication/345446991_Overview_of_the_Evalita_2018_Task_on_Automatic_Misogyny_Identification_AMI.

- [11] Pinkesh Badjatiya et al. «Deep Learning for Hate Speech Detection in Tweets». En: *Proceedings of the 26th International Conference on World Wide Web Companion - WWW '17 Companion*. WWW '17 Companion. ACM Press, 2017, págs. 759-760. DOI: 10.1145/3041021.3054223. URL: <http://dx.doi.org/10.1145/3041021.3054223>.
- [12] Jacob Devlin et al. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. 2019. arXiv: 1810.04805 [cs.CL]. URL: <https://arxiv.org/abs/1810.04805>.
- [13] Benjamin Warner et al. *Smarter, Better, Faster, Longer: A Modern Bidirectional Encoder for Fast, Memory Efficient, and Long Context Finetuning and Inference*. 2024. arXiv: 2412.13663 [cs.CL]. URL: <https://arxiv.org/abs/2412.13663>.
- [14] Gemma Team et al. *Gemma 2: Improving Open Language Models at a Practical Size*. 2024. arXiv: 2408.00118 [cs.CL]. URL: <https://arxiv.org/abs/2408.00118>.
- [15] AI at Meta. *The Llama 3 Herd of Models*. 2024. URL: <https://ai.meta.com/research/publications/the-llama-3-herd-of-models>.
- [16] Hugo Touvron et al. *Llama 2: Open Foundation and Fine-Tuned Chat Models*. 2023. arXiv: 2307.09288 [cs.CL]. URL: <https://arxiv.org/abs/2307.09288>.
- [17] Albert Q. Jiang et al. *Mistral 7B*. 2023. arXiv: 2310.06825 [cs.CL]. URL: <https://arxiv.org/abs/2310.06825>.
- [18] Emily Sheng et al. *The Woman Worked as a Babysitter: On Biases in Language Generation*. 2019. arXiv: 1909.01326 [cs.CL]. URL: <https://arxiv.org/abs/1909.01326>.
- [19] Emmet Fear. *Can you run Google's Gemma 2B on an RTX A4000? Here's how*. Mayo de 2025. URL: <https://www.runpod.io/articles/guides/run-google-gemma-2b-on-rtx-a4000>.
- [20] Jinhao Li et al. *Large Language model inference Acceleration: A comprehensive hardware perspective*. Oct. de 2024. URL: <https://arxiv.org/abs/2410.04466>.
- [21] mistralai. *Mistral-7B-Instruct-v0.3*. URL: <https://huggingface.co/mistralai/Mistral-7B-Instruct-v0.3>.
- [22] Francisco Rodríguez-Sánchez et al. «Overview of EXIST 2021: sEXism Identification in Social neTworks». En: *Procesamiento del Lenguaje Natural* 67.0 (2021), págs. 195-207. ISSN: 1989-7553. URL: <http://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6389>.
- [23] Francisco Rodríguez-Sánchez et al. «Overview of EXIST 2022: sEXism Identification in Social neTworks». En: *Procesamiento del Lenguaje Natural* 69.0 (2022), págs. 229-240. ISSN: 1989-7553. URL: <http://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6443>.
- [24] Xuan Luo et al. «BeyondGender: a multifaceted bilingual dataset for practical sexism detection». En: *Proceedings of the AAAI Conference on Artificial Intelligence* 39.23 (abr. de 2025), págs. 24750-24758. DOI: 10.1609/aaai.v39i23.34656. URL: <https://ojs.aaai.org/index.php/AAAI/article/view/34656>.

-
- [25] Maarten Sap et al. «Annotators with Attitudes: How Annotator Beliefs And Identities Bias Toxic Language Detection». En: *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Ed. por Marine Carpuat, Marie-Catherine de Marneffe e Ivan Vladimir Meza Ruiz. Seattle, United States: Association for Computational Linguistics, jul. de 2022, págs. 5884-5906. DOI: 10.18653/v1/2022.naacl-main.431. URL: <https://aclanthology.org/2022.naacl-main.431/>.
- [26] Lucas Dixon et al. «Measuring and Mitigating Unintended Bias in Text Classification». En: *Proceedings of the 2018 AAAI/ACM Conference on AI, Ethics, and Society*. AIES '18. New Orleans, LA, USA: Association for Computing Machinery, 2018, págs. 67-73. ISBN: 9781450360128. DOI: 10.1145/3278721.3278729. URL: <https://doi.org/10.1145/3278721.3278729>.
- [27] Sarah Farhadpour, Timothy A. Warner y Aaron E. Maxwell. «Selecting and Interpreting Multiclass Loss and Accuracy Assessment Metrics for Classifications with Class Imbalance: Guidance and Best Practices». En: *Remote Sensing* 16.3 (2024), pág. 533. DOI: 10.3390/rs16030533.
- [28] Gayuh Tri Rahutami y Fariska Zakhralativa Ruskanda. «Sexism Detection and Classification Using RoBERTa and Data Augmentation». En: *2023 10th International Conference on Advanced Informatics: Concept, Theory and Application (ICAICTA)*. 2023, págs. 1-6. DOI: 10.1109/ICAICTA59291.2023.10390414.

Apéndice A: Tablas completas de resultados

A.1. EDOS reduced dataset (5 k rows)

A.1.1. bert-base-uncased

Tabla 1: Resultados de bert-base-uncased en el dataset EDOS (5 k)

Model Name	Num Epochs	Learning Rate	Weight Decay	Batch Size	Ev. Loss	Ev. Accuracy	Ev. Precision	Ev. Recall	Ev. F1	Ev. Runtime
bert-base-uncased	20	0.000	0.000	16	0.463	0.787	0.763	0.827	0.793	1.189
bert-base-uncased	20	0.000	0.000	32	0.480	0.813	0.806	0.819	0.812	0.751
bert-base-uncased	20	0.000	0.000	64	0.443	0.800	0.790	0.811	0.800	0.562
bert-base-uncased	20	0.000	0.001	16	0.556	0.799	0.799	0.793	0.796	1.206
bert-base-uncased	20	0.000	0.001	32	0.635	0.803	0.786	0.827	0.806	0.847
bert-base-uncased	20	0.000	0.001	64	0.467	0.790	0.763	0.835	0.797	0.584
bert-base-uncased	20	0.000	0.010	16	1.009	0.809	0.811	0.801	0.806	1.216
bert-base-uncased	20	0.000	0.010	32	0.564	0.723	0.669	0.873	0.757	0.789
bert-base-uncased	20	0.000	0.010	64	0.466	0.790	0.766	0.829	0.796	0.602
bert-base-uncased	20	0.000	0.000	16	0.697	0.818	0.819	0.811	0.815	1.207
bert-base-uncased	20	0.000	0.000	32	0.491	0.770	0.718	0.881	0.791	0.761
bert-base-uncased	20	0.000	0.000	64	0.543	0.808	0.772	0.867	0.817	0.598
bert-base-uncased	20	0.000	0.001	16	0.635	0.804	0.788	0.825	0.806	1.188
bert-base-uncased	20	0.000	0.001	32	0.491	0.770	0.718	0.881	0.791	0.784
bert-base-uncased	20	0.000	0.001	64	0.543	0.808	0.772	0.867	0.817	0.575
bert-base-uncased	20	0.000	0.010	16	1.193	0.812	0.791	0.843	0.816	1.182
bert-base-uncased	20	0.000	0.010	32	0.908	0.807	0.787	0.835	0.811	0.754
bert-base-uncased	20	0.000	0.010	64	0.422	0.806	0.798	0.813	0.806	0.577

Continued on next page

Tabla 1: Resultados de bert-base-uncased en el dataset EDOS (5 k)

Model Name	Num Epochs	Learning Rate	Weight Decay	Batch Size	Ev. Loss	Ev. Accuracy	Ev. Precision	Ev. Recall	Ev. F1	Ev. Runtime
bert-base-uncased	20	0.000	0.000	16	0.752	0.802	0.764	0.867	0.812	1.193
bert-base-uncased	20	0.000	0.000	32	0.448	0.791	0.759	0.847	0.800	0.758
bert-base-uncased	20	0.000	0.000	64	0.715	0.800	0.764	0.861	0.810	0.567
bert-base-uncased	20	0.000	0.001	16	0.465	0.819	0.819	0.813	0.816	1.183
bert-base-uncased	20	0.000	0.001	32	0.581	0.792	0.764	0.839	0.800	0.772
bert-base-uncased	20	0.000	0.001	64	0.555	0.812	0.800	0.827	0.813	0.562
bert-base-uncased	20	0.000	0.010	16	1.359	0.809	0.797	0.823	0.810	1.197
bert-base-uncased	20	0.000	0.010	32	0.436	0.795	0.744	0.893	0.812	0.717
bert-base-uncased	20	0.000	0.010	64	0.421	0.802	0.808	0.787	0.797	0.564
bert-base-uncased	20	0.000	0.000	16	0.783	0.791	0.739	0.893	0.809	1.148
bert-base-uncased	20	0.000	0.000	32	0.447	0.826	0.831	0.813	0.822	0.726
bert-base-uncased	20	0.000	0.000	64	0.889	0.812	0.795	0.835	0.815	0.556
bert-base-uncased	20	0.000	0.001	16	1.251	0.811	0.810	0.807	0.808	1.147
bert-base-uncased	20	0.000	0.001	32	0.409	0.820	0.810	0.831	0.820	0.782
bert-base-uncased	20	0.000	0.001	64	0.431	0.797	0.758	0.865	0.808	0.585
bert-base-uncased	20	0.000	0.010	16	0.452	0.829	0.852	0.791	0.820	1.152
bert-base-uncased	20	0.000	0.010	32	0.441	0.796	0.737	0.913	0.816	0.740
bert-base-uncased	20	0.000	0.010	64	0.396	0.816	0.817	0.809	0.813	0.565
bert-base-uncased	20	0.000	0.000	16	0.879	0.782	0.753	0.833	0.791	1.163
bert-base-uncased	20	0.000	0.000	32	0.431	0.801	0.829	0.753	0.789	0.758
bert-base-uncased	20	0.000	0.000	64	0.840	0.813	0.794	0.839	0.816	0.577
bert-base-uncased	20	0.000	0.001	16	0.558	0.762	0.724	0.839	0.777	1.200
bert-base-uncased	20	0.000	0.001	32	0.436	0.799	0.788	0.813	0.800	0.727
bert-base-uncased	20	0.000	0.001	64	0.494	0.768	0.697	0.940	0.800	0.569
bert-base-uncased	20	0.000	0.010	16	1.133	0.814	0.799	0.833	0.816	1.212
bert-base-uncased	20	0.000	0.010	32	0.938	0.807	0.769	0.871	0.817	0.790
bert-base-uncased	20	0.000	0.010	64	0.463	0.780	0.720	0.909	0.804	0.568
bert-base-uncased	20	0.001	0.000	16	0.731	0.495	0.495	1.000	0.662	1.191
bert-base-uncased	20	0.001	0.000	32	0.717	0.495	0.495	1.000	0.662	0.736
bert-base-uncased	20	0.001	0.000	64	0.715	0.505	0.000	0.000	0.000	0.564
bert-base-uncased	20	0.001	0.001	16	0.693	0.495	0.495	1.000	0.662	1.255
bert-base-uncased	20	0.001	0.001	32	0.698	0.495	0.495	1.000	0.662	0.741
bert-base-uncased	20	0.001	0.001	64	0.735	0.495	0.495	1.000	0.662	0.575
bert-base-uncased	20	0.001	0.010	16	0.731	0.495	0.495	1.000	0.662	1.145
bert-base-uncased	20	0.001	0.010	32	0.700	0.495	0.495	1.000	0.662	0.738
bert-base-uncased	20	0.001	0.010	64	0.736	0.495	0.495	1.000	0.662	0.570

A.1.2. ModernBERT-base

Tabla 2: Resultados de ModernBert-base en el dataset EDOS (5 k)

Model Name	Num Epochs	Learning Rate	Weight Decay	Batch Size	Ev. Loss	Ev. Accuracy	Ev. Precision	Ev. Recall	Ev. F1	Ev. Runtime
ModernBERT-base	20	0.000	0.000	16	2.129	0.801	0.747	0.903	0.818	2.394
ModernBERT-base	20	0.000	0.000	32	0.394	0.826	0.834	0.809	0.821	1.407
ModernBERT-base	20	0.000	0.000	64	0.413	0.807	0.852	0.738	0.791	0.752
ModernBERT-base	20	0.000	0.000	16	0.824	0.795	0.758	0.859	0.806	2.310
ModernBERT-base	20	0.000	0.000	32	0.405	0.817	0.823	0.803	0.813	1.257
ModernBERT-base	20	0.000	0.000	64	0.450	0.783	0.763	0.815	0.788	0.734
ModernBERT-base	20	0.000	0.010	16	1.999	0.832	0.836	0.821	0.828	2.466
ModernBERT-base	20	0.000	0.010	32	0.419	0.812	0.791	0.843	0.816	1.291
ModernBERT-base	20	0.000	0.010	64	0.509	0.754	0.691	0.909	0.785	0.766
ModernBERT-base	20	0.000	0.001	16	1.885	0.831	0.808	0.863	0.835	2.307
ModernBERT-base	20	0.000	0.001	32	0.462	0.823	0.806	0.845	0.825	1.300
ModernBERT-base	20	0.000	0.001	64	0.419	0.813	0.783	0.859	0.820	0.748
ModernBERT-base	20	0.000	0.000	16	1.435	0.839	0.836	0.839	0.837	2.454
ModernBERT-base	20	0.000	0.000	32	0.481	0.791	0.869	0.680	0.763	1.273
ModernBERT-base	20	0.000	0.000	64	0.838	0.798	0.772	0.839	0.804	0.759
ModernBERT-base	20	0.000	0.010	16	0.397	0.825	0.831	0.811	0.821	3.583
ModernBERT-base	20	0.000	0.010	32	1.204	0.821	0.811	0.831	0.821	1.331
ModernBERT-base	20	0.000	0.010	64	0.438	0.809	0.769	0.877	0.820	0.815
ModernBERT-base	20	0.000	0.001	16	1.350	0.821	0.835	0.795	0.814	2.375
ModernBERT-base	20	0.000	0.001	32	1.058	0.818	0.807	0.831	0.819	1.311
ModernBERT-base	20	0.000	0.001	64	0.500	0.758	0.716	0.847	0.776	0.754
ModernBERT-base	20	0.000	0.000	16	1.460	0.805	0.808	0.795	0.801	2.312
ModernBERT-base	20	0.000	0.000	32	1.174	0.797	0.778	0.825	0.801	1.326
ModernBERT-base	20	0.000	0.000	64	0.513	0.816	0.832	0.787	0.809	0.853
ModernBERT-base	20	0.000	0.010	16	0.950	0.833	0.805	0.873	0.838	2.435
ModernBERT-base	20	0.000	0.010	32	0.463	0.782	0.746	0.847	0.794	1.389
ModernBERT-base	20	0.000	0.010	64	0.516	0.744	0.731	0.765	0.747	0.785
ModernBERT-base	20	0.000	0.001	16	0.426	0.802	0.824	0.763	0.792	2.424
ModernBERT-base	20	0.000	0.001	32	0.427	0.793	0.822	0.742	0.780	1.329
ModernBERT-base	20	0.000	0.001	64	0.487	0.759	0.718	0.845	0.776	0.731
ModernBERT-base	20	0.000	0.000	16	0.831	0.788	0.749	0.859	0.800	2.419
ModernBERT-base	20	0.000	0.000	32	0.601	0.770	0.744	0.817	0.779	1.292
ModernBERT-base	20	0.000	0.000	64	0.476	0.810	0.814	0.799	0.806	0.759
ModernBERT-base	20	0.000	0.010	16	0.519	0.819	0.808	0.831	0.819	2.482
ModernBERT-base	20	0.000	0.010	32	0.603	0.676	0.619	0.895	0.732	1.278
ModernBERT-base	20	0.000	0.010	64	0.582	0.686	0.646	0.805	0.717	0.757

Continued on next page

Tabla 2: Resultados de ModernBert-base en el dataset EDOS (5k)

Model Name	Num Epochs	Learning Rate	Weight Decay	Batch Size	Ev. Loss	Ev. Accuracy	Ev. Precision	Ev. Recall	Ev. F1	Ev. Runtime
ModernBERT-base	20	0.000	0.001	16	0.890	0.801	0.793	0.809	0.801	2.398
ModernBERT-base	20	0.000	0.001	32	0.590	0.686	0.632	0.873	0.733	1.292
ModernBERT-base	20	0.000	0.001	64	0.508	0.784	0.804	0.744	0.773	0.747
ModernBERT-base	20	0.000	0.000	16	0.463	0.786	0.729	0.903	0.807	3.897
ModernBERT-base	20	0.000	0.000	32	1.076	0.804	0.754	0.895	0.819	1.291
ModernBERT-base	20	0.000	0.000	64	0.451	0.797	0.745	0.895	0.814	0.739
ModernBERT-base	20	0.000	0.010	16	1.064	0.822	0.801	0.851	0.825	2.417
ModernBERT-base	20	0.000	0.010	32	0.776	0.767	0.696	0.940	0.800	1.313
ModernBERT-base	20	0.000	0.010	64	0.393	0.826	0.818	0.833	0.826	0.780
ModernBERT-base	20	0.000	0.001	16	0.575	0.815	0.822	0.799	0.810	2.360
ModernBERT-base	20	0.000	0.001	32	1.135	0.779	0.754	0.821	0.786	1.312
ModernBERT-base	20	0.000	0.001	64	1.672	0.780	0.730	0.881	0.799	0.738
ModernBERT-base	20	0.001	0.000	16	0.710	0.734	0.692	0.835	0.757	2.619
ModernBERT-base	20	0.001	0.000	32	0.539	0.721	0.658	0.907	0.763	1.281
ModernBERT-base	20	0.001	0.000	64	0.727	0.730	0.683	0.849	0.757	0.757
ModernBERT-base	20	0.001	0.010	16	0.720	0.732	0.721	0.748	0.734	2.366
ModernBERT-base	20	0.001	0.010	32	0.586	0.742	0.731	0.759	0.744	1.336
ModernBERT-base	20	0.001	0.010	64	0.516	0.765	0.718	0.865	0.785	0.754
ModernBERT-base	20	0.001	0.001	16	0.698	0.759	0.721	0.837	0.775	2.307
ModernBERT-base	20	0.001	0.001	32	0.549	0.751	0.739	0.769	0.753	1.321
ModernBERT-base	20	0.001	0.001	64	0.903	0.720	0.711	0.732	0.722	0.776

A.2. EDOS reduced dataset (10 k rows)

A.2.1. bert-base-uncased

Tabla 3: Resultados de bert-base-uncased en el dataset EDOS (10 k)

Model Name	Num Epochs	Learning Rate	Weight Decay	Batch Size	Ev. Loss	Ev. Accuracy	Ev. Precision	Ev. Recall	Ev. F1	Ev. Runtime
bert-base-uncased	20	0.000	0.010	16	0.401	0.836	0.828	0.844	0.836	2.253
bert-base-uncased	20	0.000	0.000	32	0.417	0.835	0.836	0.828	0.832	1.543
bert-base-uncased	20	0.000	0.000	16	0.406	0.831	0.827	0.834	0.831	2.221
bert-base-uncased	20	0.000	0.001	32	0.604	0.829	0.829	0.827	0.828	1.442
bert-base-uncased	20	0.000	0.010	16	0.855	0.787	0.730	0.904	0.808	2.441

A.2.2. ModernBERT-base

Tabla 4: Resultados de ModernBERT en el dataset EDOS (10 k)

Model Name	Num Epochs	Learning Rate	Weight Decay	Batch Size	Ev. Loss	Ev. Accuracy	Ev. Precision	Ev. Recall	Ev. F1	Ev. Runtime
ModernBERT-base	20	0.000	0.010	16	1.559	0.843	0.835	0.853	0.843	4.985
ModernBERT-base	20	0.000	0.001	16	0.387	0.835	0.801	0.888	0.842	5.287
ModernBERT-base	20	0.000	0.010	16	0.402	0.832	0.825	0.838	0.832	4.599
ModernBERT-base	20	0.000	0.000	16	1.714	0.822	0.816	0.828	0.822	4.524
ModernBERT-base	20	0.000	0.010	64	0.463	0.817	0.813	0.820	0.816	1.464

Apéndice B: Prompts empleados en los LLMs

B.1. Clasificación con 2 etiquetas

```
[System]
You are a STRICT text-classifier that detects sexism. Return **one
↪ digit** only: '0' or '1'. Nothing else.

- Output '1' (sexist): Any explicit insult, stereotype, hostility or
↪ declaration that women are inferior, worthless or only sexual
↪ objects.
- Output '0' (not sexist): Neutral, positive or negative content
↪ **not** aimed at women for being women.

### Examples
Text: 'Spread awareness that being a good person wont get you
↪ anywhere with femoids.'
Answer: 1
Reason: Uses the slur “femoids” to de-humanise women and asserts
↪ hostility toward them.
---
Text: 'Are you a female?'
Label: 0
Reason: A neutral question about the person’s gender; no negative
↪ judgement.
---
Text: 'Notice how women never shut the fuck up?'
Answer: 1
Reason: Hostile generalisation that all women talk too much;
↪ explicit insult.
---
Text: 'The judge should be the victim of the female serial killer.'
Answer: 0
Reason: The threat targets the judge, not women; “female” is only
↪ descriptive.
---
Text: 'Go fuck yourselves. I'm so sick of women like this piece of
↪ shit.'
Answer: 1
Reason: Direct profanity and hatred aimed specifically at women.
---
```

```
Text: 'Horror as christian woman stabbed for reading the bible in
↳ migrant centre.'
Answer: 0
Reason: A factual headline; mentions a woman but contains no sexist
↳ content.
### End examples

### Text to classify
{text}
### Output
(one digit: 0 or 1)
```

B.2. Clasificación con 3 etiquetas

```
[System]
You are a STRICT text-classifier that detects sexism. Return **one
↳ digit** only: '0', '1', or '2'. Nothing else.

- Output '2' (sexist): Any explicit insult, stereotype, hostility or
↳ declaration that women are inferior, worthless or only sexual
↳ objects.
- Output '1' (unsure): Borderline / implicit sexism, sexualisation,
↳ mild slur or you genuinely can't decide if sexism is present.
- Output '0' (not sexist): Neutral, positive or negative content
↳ **not** aimed at women for being women.

### Examples
Text: 'Spread awareness that being a good person wont get you
↳ anywhere with femoids.'
Answer: 2
Reason: Uses the slur "femoids" to de-humanise women and asserts
↳ hostility toward them.
---
Text: 'Habits are hard to die, as much as the cock carousel she rode
↳ all her life.'
Label: 1
Reason: It's implying she is a slut.
---
Text: 'Are you a female?'
Label: 0
Reason: A neutral question about the person's gender; no negative
↳ judgement.
---
Text: 'Notice how women never shut the fuck up?'
Answer: 2
Reason: Hostile generalisation that all women talk too much;
↳ explicit insult.
---
Text: 'Most here would fuck her.'
Answer: 1
Reason: Backhanded gendered compliments.
---
```

```

Text: 'The judge should be the victim of the female serial killer.'
Answer: 0
Reason: The threat targets the judge, not women; 'female' is only
↳ descriptive.
---
Text: 'Go fuck yourselves. I'm so sick of women like this piece of
↳ shit.'
Answer: 2
Reason: Direct profanity and hatred aimed specifically at women.
---
Text: 'She loves but you, but since she's young she still wants to
↳ fuck other guys. Drop her.'
Answer: 1
Reason: Implies that young women are inherently promiscuous - a
↳ negative stereotype.
---
Text: 'Horror as christian woman stabbed for reading the bible in
↳ migrant centre.'
Answer: 0
Reason: A factual headline; mentions a woman but contains no sexist
↳ content.
### End examples

### Text to classify
{text}
### Output
(one digit: 0, 1 or 2)

```

B.3. Clasificación con 4 etiquetas

```

[System]
You are a STRICT text-classifier that detects sexism and its
↳ annotation consensus level.
Return one digit only: '0', '1', '2' or '3'. Nothing else.

- Output '3' (sexist - high consensus): All three annotators agreed
↳ the text is sexist.
- Output '2' (sexist - medium consensus): Two out of three
↳ annotators judged it sexist.
- Output '1' (sexist - low consensus): Only one annotator judged it
↳ sexist (borderline / unclear).
- Output '0' (not sexist): All three annotators agreed it is not
↳ sexist.

Guidelines (apply to decide between 0 vs 1-3):
- *Sexist* includes insults, stereotypes, hostility or
↳ objectification directed at women for being women.
- *Not sexist* may mention women neutrally/positively or criticise
↳ an individual without implying gender inferiority.
- If signs of sexism are present but ambiguous = 1.
- The stronger / more explicit the sexism, the higher the digit (2
↳ or 3).

```

Examples

Text: 'Spread awareness that being a good person wont get you
↳ anywhere with femoids.'

Answer: 3

Reason: Uses the slur "femoids" to de-humanise women and asserts
↳ hostility toward them.

Text: 'Habits are hard to die, as much as the cock carousel she rode
↳ all her life.'

Label: 2

Reason: It's implying she is a slut.

Text: 'One small way of replying to this manipulation get
↳ sterilized. Do not breed with these women, ever.'

Label: 1

Reason: Calls women manipulative 'breeders' and urges men to avoid
↳ them.

Text: 'Are you a female?'

Label: 0

Reason: A neutral question about the person's gender; no negative
↳ judgement.

Text: 'Notice how women never shut the fuck up?'

Answer: 3

Reason: Hostile generalisation that all women talk too much;
↳ explicit insult.

Text: 'Most here would fuck her.'

Answer: 2

Reason: Backhanded gendered compliments.

Text: 'I am actually glad they made women clean that.'

Label: 1

Reason: Applauds the stereotype that cleaning is women's job.

Text: 'The judge should be the victim of the female serial killer.'

Answer: 0

Reason: The threat targets the judge, not women; "female" is only
↳ descriptive.

Text: 'Go fuck yourselves. I'm so sick of women like this piece of
↳ shit.'

Answer: 3

Reason: Direct profanity and hatred aimed specifically at women.

Text: 'Won't miss her liberal wrinkly ass! Bye bitch.'

Label: 2

Reason: Uses the gendered slur 'bitch' alongside demeaning body
↳ comments.

Text: 'She loves but you, but since she's young she still wants to
↪ fuck other guys. Drop her.'

Answer: 1

Reason: Implies that young women are inherently promiscuous - a
↪ negative stereotype.

Text: 'Horror as christian woman stabbed for reading the bible in
↪ migrant centre.'

Answer: 0

Reason: A factual headline; mentions a woman but contains no sexist
↪ content.

End examples

Text to classify

{text}

Output

(one digit: 0, 1, 2 or 3)

Glosario

early stopping parada temprana del entrenamiento para evitar sobreajuste

fine-tuning ajuste fino o re-entrenamiento supervisado de un modelo ya pre-entrenado

prompting ingeniería de instrucciones (*prompts*) para guiar la salida de un LLM

accuracy Exactitud

AUPRC área bajo la curva de precisión-recobrado (PR)

AUROC área bajo la curva ROC; métrica de clasificación

BERT *Bidirectional Encoder Representations from Transformers*; encoder bidireccional de Google

CNN *Convolutional Neural Network*; red neuronal convolucional

F1 Medida F1

FastAPI framework ligero en Python para APIs REST

GPT *Generative Pre-trained Transformer*; familia de modelos generativos autoregresivos

LLM *Large Language Model*; modelo de lenguaje de gran tamaño

LoRA *Low-Rank Adaptation*; técnica de ajuste fino ligero mediante matrices de bajo rango

LSTM *Long Short-Term Memory*; variante de RNN con puertas de memoria

machine learning aprendizaje automático

MLM *Masked Language Modeling*; tarea de pre-entrenamiento que enmascara tokens

precision Precisión

QLoRA versión cuantizada de LoRA para reducir memoria GPU

React biblioteca JavaScript para construir interfaces de usuario

recall Exhaustividad, Sensibilidad, Recuperación o Cobertura

REST estilo de arquitectura para servicios web basado en recursos HTTP

RNN *Recurrent Neural Network*; red neuronal recurrente

RoPE *Rotary Positional Embedding*; codificación posicional rotatoria

sexist (high confidence) comentario marcado sexista por dos anotadores

sexist (low confidence) comentario marcado sexista por un solo anotador

soft sexism sexismo de intensidad baja o ambiguo (etiqueta de la taxonomía)

Transformer arquitectura basada en mecanismos de atención propuesta por Vaswani et al. (2017)

unsure categoría de anotación para casos con desacuerdo o duda

VRAM memoria de vídeo de la tarjeta gráfica

word2vec técnica de *embeddings* léxicos basada en contexto local (Mikolov et al. 2013)

